

Neuromorphic Lab: Simulador Modular de Memristores y Circuitos Neuromórficos

Tesis de Grado – Validación Cuantitativa y Arquitectura Hardware

Yamil Uchani

8 de octubre de 2026

Índice general

Resumen	IX
Nomenclatura y Acrónimos	X
1. Introducción	1
1.1. Contexto y motivación	1
1.2. Planteamiento del problema	1
1.3. Objetivos	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
2. Marco Teórico	3
2.1. Fundamentos del Memristor	3
2.1.1. Modelo matemático de Strukov (2008)	3
2.1.2. Modelo de Yakopcic y Prezioso (2011, 2014, 2015)	3
2.1.3. Memristores volátiles para nodos sensoriales	4
2.2. Modelo de Neurona Spiking LIF	4
2.3. Plasticidad Sináptica	4
2.3.1. Plasticidad dependiente del tiempo de disparo (STDP)	4
2.3.2. Plasticidad modulada por recompensa (R-STDP)	5
3. Fase 1: Núcleo del Dispositivo Memristivo y Variabilidad	6
3.1. Etapa 1.1: Modelo Base y Curvas Características	6
3.1.1. Implementación Cualitativa y Fundamentos Físicos	6
3.1.2. Validación Cuantitativa de Curvas $I - V$	7
3.2. Etapa 1.2: Variabilidad Estocástica	10
3.2.1. Implementación Cualitativa de No-Idealidades	10
3.2.2. Validación Cuantitativa Estadística	11
4. Fase 2: Neuronas Spiking y Sistema Híbrido	13
4.1. Etapa 2.1: Neurona LIF y Acoplamiento Híbrido	13
4.1.1. Implementación Cualitativa y Teoría Física	13
4.1.2. Validación Cuantitativa Computacional	14

5. Fase 3: Plasticidad Sináptica	18
5.1. Etapa 3.1: LTP/LTD y STDP	18
5.1.1. Implementación Cualitativa (LTP/LTD)	18
5.1.2. Implementación Cualitativa (STDP)	19
5.1.3. Validación Cuantitativa de Aprendizaje (Frente a Datos Físicos)	21
6. Fase 4: Arquitecturas Matriciales, No Idealidades y Control Robótico Autónomo	25
6.1. Etapa 4.1: Matriz Crossbar e In-Memory	25
6.1.1. Implementación Cualitativa (Operación Analógica 1×1)	25
6.1.2. Validación Cuantitativa Computacional de Red Experimental (Prezioso 2015)	26
6.2. Etapa 4.2: Integración Neuromórfica en Hardware Memristivo para Control Robótico (NeuroBot 24×12)	29
6.2.1. Arquitectura del Sistema (24×12)	29
6.2.2. Regla de Aprendizaje R-STDP y Traza Volátil	30
6.2.3. Resultados Experimentales y Discusión en Control Robótico	30
6.3. Validación del Modelo Físico del Crossbar (Suite de 10 Experimentos)	32
6.3.1. Exp. 1 — Corrientes parásitas vs. tamaño (sneak ratio)	32
6.3.2. Exp. 2 — MNA real vs. modelo ideal	33
6.3.3. Exp. 3 — Caída de tensión en línea (R_{wire})	34
6.3.4. Exp. 4 — Precisión en VMM	34
6.3.5. Exp. 5 — Half-select disturb: $V/2$ vs. $V/3$	34
6.3.6. Exp. 6 — Retención de estado (no volatilidad)	35
6.3.7. Exp. 7 — Linealidad LTP/LTD	35
6.3.8. Exp. 8 — Variabilidad dispositivo a dispositivo (D2D)	35
6.3.9. Exp. 9 — Costo computacional del solver MNA	36
6.3.10. Exp. 10 — Crosstalk entre columnas	37
6.3.11. Síntesis de Conclusiones de Fase 4	37
7. Discusión de Resultados y Limitaciones	38
7.1. Discusión de Resultados	38
7.2. Limitaciones del Estudio	38
7.3. Reproducibilidad y Código Abierto	39
8. Conclusiones	40
8.1. Conclusiones Principales	40
8.2. Contribuciones del Trabajo	40
9. Marco Práctico	41
9.1. Esquema general del proyecto	41
9.2. Herramientas	42
9.2.1. Hardware	42
9.2.2. Software	42

9.3.	Desarrollo	42
9.3.1.	Etapa 1 – Modelado del dispositivo memristivo	43
9.3.2.	Etapa 2 – Neurona LIF y sistema híbrido	44
9.3.3.	Etapa 3 – Plasticidad sináptica	46
9.3.4.	Etapa 4 – Crossbar e in-memory computing	47
9.3.5.	Etapa 5 – Integración con agente de control autónomo	50
9.3.6.	Etapa 6 – Extensión a percepción visual	52
9.3.7.	Etapa 7 – Navegación autónoma con obstáculos	54
9.4.	Resultados y discusión	57
9.4.1.	Métricas comparativas entre tareas	57
9.4.2.	Especialización del sustrato según la tarea	58
9.4.3.	Ablaciones A/B/C/D	58
9.4.4.	Limitaciones	59
9.5.	Análisis de costos	59
A.	Estructura del Código Fuente y Módulos	60
A.1.	Árbol de directorios del paquete <code>neurolab</code>	60
A.2.	Descripción de los módulos principales	61
A.3.	Resumen de la suite de pruebas unitarias (Pytest)	62
A.4.	Fragmentos de Código Centrales	62
A.4.1.	Modelo Matemático de Strukov (<code>strukov.py</code>)	62
A.4.2.	Motor de Integración Base (<code>base_device.py</code>)	63
B.	Conjuntos de Datos, Scripts y Métricas de Validación	64
B.1.	Conjuntos de datos de referencia (CSVs)	64
B.2.	Catálogo de figuras generadas	65
B.3.	Tabla maestra de las 27 validaciones cuantitativas	65

Índice de figuras

3.1. Respuesta cualitativa del dispositivo Strukov frente a estimulación triangular, validando el confinamiento estricto del estado interno.	7
3.2. Validación cuantitativa rigurosa Strukov 2008 vs simulador neurolab en seis paneles (Histéresis I-V, Corriente, Estado, Resistencia, Conductancia y Potencia). .	8
3.3. Consistencia de la resistencia R en función de la variable de estado interna x . . .	9
3.4. Análisis de estabilidad numérica bajo pasos de integración temporal dt extremos.	9
3.5. Validación cuantitativa contra Prezioso et al. (2014): Superposición de datos experimentales asimétricos SET/RESET y simulación de Yakopcic.	10
3.6. Caracterización cuantitativa de variabilidad D2D (test KS) y variabilidad temporal C2C (proceso estocástico).	11
3.7. Sensibilidad del dispositivo ante la inyección de ruido estocástico térmico.	12
3.8. Distribución y tests estadísticos acumulados para múltiples instancias de variabilidad D2D.	12
4.1. Respuesta cualitativa del sistema híbrido: Potencial de membrana $V_C(t)$ evidenciando la aceleración temporal (top), Resistencia $R_S(t)$ descendente (centro), e Intervalo Inter-Spike (ISI) modularizado (abajo).	14
4.2. Verificación de la resistencia en serie R_S proveniente de la dinámica de acoplamiento de x	15
4.3. Validación analítica subumbral de la neurona LIF frente a la solución RC exacta en respuesta al impulso.	16
4.4. Validación cuantitativa del factor de compresión de ISI y de la tasa de disparo $f(t)$ contra los datos empíricos de HfO_2 de Wang et al. (2025).	17
5.1. Implementación cualitativa analítica de Potenciación (LTP) y Depresión (LTD) mediante secuencias continuas de pulsos de voltaje idénticos.	18
5.2. Validación de robustez cualitativa: Ciclado reversible continuo y estable tras 100 repeticiones completas de LTP/LTD sin deriva apreciable.	19
5.3. Esquema cualitativo fisiológico del solapamiento de espigas $V_{\text{pre}}(t)$ y $V_{\text{post}}(t)$ requerido para desencadenar STDP asimétrico.	20
5.4. Acumulación temporal de pesos sinápticos durante el protocolo STDP, ilustrando explícitamente tanto los regímenes de Potenciación (LTP) para desfases $\Delta t > 0$, como de Depresión (LTD) para $\Delta t < 0$	21

5.5. Validación cuantitativa de la ventana bi-exponencial STDP sobreponiendo la predicción teórica del simulador contra la matriz de puntos discretos CSV de Jo et al. (2010).	22
5.6. Validación cuantitativa LTP/LTD. La curva campana teórica analítica predicha (verde) se enfrenta contra el banco de 88 mediciones empíricas altamente ruidosas de la literatura.	23
5.7. Caracterización simultánea de voltaje, corriente, resistencia y conductancia durante pulsos LTP y LTD.	24
6.1. Verificación íntegra, cualitativa y funcional de computación In-Memory en el bloque elemental Crossbar analógico.	26
6.2. Validación cuantitativa de barrido dieléctrico ultra-resistivo frente al estado virgen experimental de Prezioso 2015 Fig S3a.	27
6.3. Mediciones cruzadas cuantitativas y estadísticas sobre la dispersión de red nativa, en alineación exhaustiva a S3b y S3c (Prezioso 2015).	28
6.4. Validación de asimetría SET/RESET sobre la matriz en configuración Prezioso extendida.	28
6.5. Curva de aprendizaje del agente en arquitectura 24×12 . La media convergente es $\bar{R} \approx 270$ debido a la alta varianza inicial; sin embargo, 3 de las 5 semillas lograron convergencia ultrarrápida al máximo teórico ($\bar{R} > 480$) en < 30 episodios. La banda de confianza representa $\pm 1\sigma$ sobre todas las semillas.	30
6.6. Estudio de ablación comparativo (A, B, C, D) en el crossbar 24×12	31
6.7. Heatmap del estado interno de conductancias X tras la convergencia del agente.	32
6.8. Sneak ratio vs. tamaño. Crecimiento monótono confirma el efecto parásito escalar.	33
6.9. Diagrama de dispersión MNA vs. Ideal. El error crece de forma no lineal con N	33
6.10. Perfil de I_{col} para distintos R_{wire} . Mayor resistencia implica mayor no-uniformidad.	34
6.11. Histograma del error relativo en VMM por tamaño de crossbar.	34
6.12. Evolución de X para celda fully-, half- y no-selected bajo 3 pulsos.	35
6.13. Media de X durante 1000 pasos en reposo. Variación nula = retención perfecta.	35
6.14. LTP/LTD y derivada discreta. La no-linealidad satura suavemente los extremos.	36
6.15. Dispersión de I_{col} y variación de $\bar{G}_{\text{mean}}$ entre 20 crossbars virtuales.	36
6.16. Costo del solver MNA en log-log. Ajuste empírico $\mathcal{O}(N^{0.88})$	36
6.17. I_{col} real vs. ideal al excitar únicamente la fila 0.	37
9.1. Arquitectura general del ecosistema. El laboratorio (<i>arriba</i>) provee los modelos físicos; el simulador robótico (<i>abajo</i>) los integra en un agente de control.	42
9.2. Validación cuantitativa de los modelos memristivos implementados. Izquierda: lazo de histéresis del modelo de Strukov contra datos de Nature 2008. Derecha: asimetría SET/RESET del modelo de Prezioso contra datos de Nature Communications 2014.	43
9.3. Caracterización cuantitativa de variabilidad D2D (histograma de R_{ON} con ajuste normal) y variabilidad temporal C2C (trayectoria del proceso de Ornstein-Uhlenbeck y función de autocorrelación).	44

9.4. Validación analítica subumbral de la neurona LIF. Panel superior: solución exacta (azul) contra integración Euler (marcadores). Panel inferior: respuesta supraliminal con tren de pulsos.	45
9.5. Respuesta del sistema híbrido memristor–neurona. Panel superior: potencial de membrana. Panel central: resistencia sináptica. Panel inferior: intervalo inter-spike en escala logarítmica.	46
9.6. Implementación cualitativa de LTP y LTD mediante secuencias continuas de pulsos idénticos. La conductancia se modifica de forma gradual con saturación asintótica en los extremos.	47
9.7. Validación cuantitativa de la ventana STDP bi-exponencial contra los puntos experimentales de Jo et al. (2010). Modelo analítico (línea verde) contra datos discretos (marcadores rojos y azules).	47
9.8. Crecimiento monótono del sneak ratio al escalar el arreglo crossbar desde $N = 4$ hasta $N = 32$ filas, con $M = 12$ columnas fijas.	48
9.9. Comparación entre corrientes calculadas por el solver MNA completo y el modelo ideal $I = G \cdot V$ para cuatro tamaños de arreglo. La desviación respecto a la recta identidad refleja el impacto acumulado de las corrientes parásitas.	49
9.10. Perfil de corriente por columna para distintos valores de resistencia de línea R_{wire} . A mayor resistencia, mayor no-uniformidad en la lectura.	50
9.11. Arquitectura del agente neuromórfico. La observación se codifica en voltajes de fila, se propaga por el crossbar, se integra en neuronas LIF, y se decodifica en una acción. El aprendizaje se aplica al final del episodio.	51
9.12. Curva de aprendizaje del agente en CartPole-v1. La media móvil sobre cinco semillas alcanza convergencia a la recompensa máxima en menos de 30 episodios.	52
9.13. Arquitectura del clasificador neuromórfico. La imagen se codifica en voltajes de fila, se propaga por el crossbar 64×8 , y la corriente de cada columna se normaliza en una distribución de probabilidad sobre las clases.	53
9.14. Curva de aprendizaje del clasificador sobre los ocho patrones, semilla 0. Media móvil de 100 episodios; la línea discontinua marca el nivel aleatorio $1/8$	54
9.15. Robustez entre semillas: las tres corridas independientes (5000 episodios cada una) convergen a 100 % de acierto sobre los ocho patrones.	54
9.16. Entorno de navegación: gridworld 10×10 con quince celdas de obstáculo (gris), punto de inicio (azul) y meta (verde). La disposición es determinística por semilla y garantiza un camino válido.	56
9.17. Trayectorias sobre el entorno de la semilla 2. Izquierda: episodio 0 con política aleatoria. Derecha: roll-out determinístico de la política aprendida, que alcanza la meta en 19 pasos.	56
9.18. Tasa de éxito de la navegación (media móvil de 50 episodios) para las tres semillas. La línea discontinua marca el nivel aleatorio (4.2 %) y la mejor semilla converge a 99 %.	57

9.19. Arquitectura del agente de navegación. El mismo crossbar R-STDP de las etapas anteriores, con $N = 16$ filas y $M = 4$ columnas, procesa el parche sensorial 3×3 y la posición para producir la acción.	57
--	----

Índice de tablas

3.1. Métricas de validación cuantitativa contra Strukov et al. (2008).	8
9.1. Comparación de las tres tareas resueltas con el mismo sustrato memristivo y la misma regla R-STDP. La métrica se evalúa sobre los últimos 200 episodios de cada corrida (500 en el caso de visión); $\bar{X}$ y σ_X son la media y la desviación estándar de la matriz de pesos al final del entrenamiento.	58
9.2. Estudio de ablaciones: protocolo original vs reproducción con física real. Los valores corresponden a $\bar{R}_{50}$ (media de recompensa en los últimos 50 episodios). . .	58
A.1. Resumen de módulos del paquete neurolab	61
A.2. Distribución de las 87 pruebas unitarias e integradas (todas pasando satisfactoriamente).	62
B.1. Conjuntos de datos experimentales digitalizados incluidos en neuromorphic_lab/validaciones/datos	
B.2. Catálogo consolidado de las 23 figuras representativas e integradas en la tesis. . .	65
B.3. Resumen consolidado de las 27 validaciones del proyecto Neuromorphic Lab. . . .	65

Resumen

Este documento presenta la validación cuantitativa y cualitativa del simulador Neuromorphic Lab, una plataforma modular diseñada para el estudio de dispositivos memristivos y arquitecturas neuromórficas. El desarrollo se dividió en cuatro fases: modelado de la celda unitaria de Strukov, integración híbrida con neuronas Leaky Integrate-and-Fire (LIF), implementación de plasticidad sináptica (STDP, LTP/LTD) y escalamiento a matrices In-Memory Computing (Crossbar). Los resultados demuestran una altísima correlación ($R^2 > 0,93$) con datos empíricos de literatura científica de referencia (Strukov 2008, Jo 2010, Prezioso 2015, Wang 2025), validando la viabilidad del simulador como herramienta rigurosa para la investigación en hardware neuromórfico, logrando reproducir fielmente fenómenos de variabilidad estocástica, asimetría de conmutación y computación paralela analógica.

Nomenclatura y Acrónimos

Acrónimos

- **C2C**: Cycle-to-Cycle (Variabilidad ciclo a ciclo)
- **D2D**: Device-to-Device (Variabilidad dispositivo a dispositivo)
- **ISI**: Inter-Spike Interval (Intervalo entre pulsos)
- **LIF**: Leaky Integrate-and-Fire (Modelo neuronal)
- **LTD**: Long-Term Depression (Depresión a largo plazo)
- **LTP**: Long-Term Potentiation (Potenciación a largo plazo)
- **STDP**: Spike-Timing-Dependent Plasticity (Plasticidad dependiente del tiempo)
- **VMM**: Vector-Matrix Multiplication (Multiplicación vector-matriz)

Símbolos

- G : Conductancia (Ω^{-1} o Siemens)
- R_S : Resistencia en serie (Ω)
- V_{th} : Voltaje de umbral (V)
- x : Variable de estado interna (adimensional o nm)
- w : Ancho de la región dopada (nm)
- D : Espesor total del dispositivo (nm)

Capítulo 1

Introducción

1.1. Contexto y motivación

El crecimiento exponencial de las aplicaciones de inteligencia artificial y procesamiento de datos ha puesto en evidencia las limitaciones intrínsecas de la arquitectura computacional von Neumann tradicional. La separación física entre las unidades de procesamiento central (CPU/GPU) y las memorias secundarias genera un cuello de botella de ancho de banda y un consumo energético insostenible, conocido como el *cuello de botella de von Neumann*.

La computación neuromórfica surge como una alternativa paradigmática inspirada en la arquitectura y dinámica de los sistemas biológicos cerebrales. Al integrar la memoria y el procesamiento en el mismo elemento físico mediante redes de memristores y neuronas artificiales tipo Disparo e Integración con Fuga (*Leaky Integrate-and-Fire*, LIF), es posible reducir el consumo energético en varios órdenes de magnitud y habilitar el aprendizaje en tiempo real en dispositivos de borde (*edge computing*).

1.2. Planteamiento del problema

A pesar de los avances teóricos en dispositivos memristivos y modelos de neuronas de impulsos (*spiking neurons*), existe una brecha significativa entre la modelación analítica aislada y las plataformas de simulación de circuitos completos integrados. Los simuladores existentes frecuentemente presentan uno o más de los siguientes inconvenientes:

1. Falta de modularidad para intercambiar dinámicamente modelos de memristores no volátiles (Strukov, Prezioso, Jo) y volátiles (Wang, Yang).
2. Omisión de efectos no ideales deterministas y estocásticos reales, como la variabilidad dispositivo a dispositivo (*device-to-device*, D2D) y ciclo a ciclo (*cycle-to-cycle*, C2C).
3. Dificultad para validar de forma automatizada y reproducible la precisión numérica frente a datos experimentales publicados en la literatura.

1.3. Objetivos

1.3.1. Objetivo general

Desarrollar y validar cuantitativamente una plataforma de simulación modular en Python (*Neuromorphic Lab*) para la modelación y análisis de dispositivos memristivos, neuronas LIF, circuitos híbridos y matrices de interconexión (*crossbar array*), con interfaz gráfica interactiva y verificación automatizada contra datos de la literatura.

1.3.2. Objetivos específicos

1. Implementar una biblioteca centralizada de modelos físicos y matemáticos de memristores (Strukov, Yakopcic/Prezioso, Jo, Wang) y neuronas LIF.
2. Incorporar variabilidad estocástica D2D y C2C mediante distribuciones normales truncadas y procesos de Ornstein-Uhlenbeck.
3. Diseñar e integrar algoritmos de plasticidad sináptica Hebbiana (*Spike-Timing-Dependent Plasticity*, STDP) y reforzada (*R-STDP*).
4. Consolidar la arquitectura de matrices crossbar (1CE1, 2CE2, 4CE4) en una implementación unificada con decodificadores y controladores de fila/columna.
5. Construir una suite de 27 pruebas de validación automatizadas reportando métricas de precisión (MAE, RMSE, Error Relativo y R^2).

Capítulo 2

Marco Teórico

2.1. Fundamentos del Memristor

El memristor (*memory resistor*), postulado hipotéticamente por Leon Chua en 1971 como el cuarto elemento pasivo fundamental de circuito y sintetizado por primera vez en laboratorios de HP por Strukov et al. en 2008 [1], establece una relación directa entre la carga eléctrica acumulada q y el flujo magnético φ :

$$d\varphi = M(q) dq \quad (2.1)$$

La resistencia equivalente del dispositivo, denominada *memristancia* $M(w)$, depende dinámicamente de una variable interna de estado $x(t) = w(t)/D \in [0, 1]$, que representa la frontera física entre la zona dopada y no dopada del material.

2.1.1. Modelo matemático de Strukov (2008)

En el modelo de Strukov et al. [1], la resistencia total $R(x)$ se expresa como una combinación lineal estricta de las resistencias extremas en estado ON (R_{ON}) y OFF (R_{OFF}):

$$R(x) = R_{\text{ON}} \cdot x + R_{\text{OFF}} \cdot (1 - x) \quad (2.2)$$

La ecuación diferencial de evolución del estado interno $x(t)$ bajo una corriente $i(t)$ es:

$$\frac{dx}{dt} = \mu_v \cdot \frac{R_{\text{ON}}}{D^2} \cdot i(t) \cdot f(x) \quad (2.3)$$

donde μ_v es la movilidad promedio de vacancias de oxígeno y $f(x)$ representa una función de ventana que modela los efectos de frontera no lineales en las interfaces del dispositivo.

2.1.2. Modelo de Yakopcic y Prezioso (2011, 2014, 2015)

Para capturar la asimetría umbral y la no linealidad en dispositivos de capa fina $\text{Al}_2\text{O}_3/\text{TiO}_{2-x}$ [2, 3], se emplea la formulación de Yakopcic et al. [4]. La corriente $I(v, x)$ sigue una relación exponencial con el voltaje aplicado $v(t)$:

$$I(v, x) = \begin{cases} a_1 \cdot x(t) \cdot \sinh(b \cdot v(t)), & v(t) \geq 0 \\ a_2 \cdot x(t) \cdot \sinh(b \cdot v(t)), & v(t) < 0 \end{cases} \quad (2.4)$$

donde la tasa de variación $\dot{x}(t)$ se activa únicamente al superar los voltajes umbrales de SET (V_p) y RESET (V_n):

$$\frac{dx}{dt} = \begin{cases} A_p \cdot (e^{v(t)-V_p} - 1) \cdot f(x), & v(t) > V_p \\ -A_n \cdot (e^{-v(t)-V_n} - 1) \cdot f(x), & v(t) < -V_n \\ 0, & -V_n \leq v(t) \leq V_p \end{cases} \quad (2.5)$$

2.1.3. Memristores volátiles para nodos sensoriales

A diferencia de las celdas no volátiles, los memristores volátiles (basados en HfO_2 o nanoclústeres difusivos de $\text{Ag} : \text{SiO}_2$) [5, 6] exhiben un fenómeno de relajación espontánea del estado interno hacia un valor basal x_0 debido al decaimiento térmico de las filamentaciones metálicas. La cinética de estado se modela mediante:

$$\frac{dx}{dt} = f_{\text{activación}}(v, x) - \frac{x(t) - x_0}{\tau_{\text{relax}}} \quad (2.6)$$

donde τ_{relax} determina la constante de tiempo de olvido o relajación espontánea.

2.2. Modelo de Neurona Spiking LIF

La neurona de disparo e integración con fuga (*Leaky Integrate-and-Fire*, LIF) constituye el bloque computacional primario en redes neuromórficas. El potencial de membrana $V_m(t)$ evoluciona según la ecuación diferencial:

$$C_m \frac{dV_m(t)}{dt} = I_{\text{syn}}(t) - \frac{V_m(t) - V_{\text{rest}}}{R_{\text{leak}}} \quad (2.7)$$

Cuando el potencial $V_m(t)$ alcanza el umbral de disparo V_{th} , la neurona emite un impulso (*spike*), reinicia su potencial a V_{reset} y permanece inactiva durante un período refractario t_{ref} :

$$\text{Si } V_m(t) \geq V_{\text{th}} \implies \begin{cases} S(t) = 1 \\ V_m(t^+) = V_{\text{reset}} \end{cases} \quad (2.8)$$

2.3. Plasticidad Sináptica

2.3.1. Plasticidad dependiente del tiempo de disparo (STDP)

La regla de aprendizaje Hebbiano STDP [7, 8] modifica la conductancia sináptica G_{ij} de acuerdo a la diferencia de tiempos $\Delta t = t_{\text{post}} - t_{\text{pre}}$ entre los impulsos pre y postsinápticos:

$$\Delta G = \begin{cases} A_+ \cdot \exp\left(-\frac{\Delta t}{\tau_+}\right), & \Delta t > 0 \quad (\text{Potenciación - LTP}) \\ -A_- \cdot \exp\left(\frac{\Delta t}{\tau_-}\right), & \Delta t < 0 \quad (\text{Depresión - LTD}) \end{cases} \quad (2.9)$$

2.3.2. Plasticidad modulada por recompensa (R-STDP)

En sistemas de aprendizaje por refuerzo, la modificación del peso sináptico se modula mediante una señal escalar de recompensa $R(t)$ emitida por el entorno:

$$\frac{dG_{ij}}{dt} = \eta \cdot R(t) \cdot e_{ij}(t) \quad (2.10)$$

donde $e_{ij}(t)$ representa la traza de elegibilidad acumulada producida por los emparejamientos STDP locales.

Capítulo 3

Fase 1: Núcleo del Dispositivo Memristivo y Variabilidad

Este capítulo detalla la primera fase del proyecto, enfocada en la construcción desde cero de la física del dispositivo memristivo y su variabilidad intrínseca. Se aborda la implementación teórica y cualitativa, culminando con una validación cuantitativa rigurosa contra los modelos seminales de la literatura científica.

3.1. Etapa 1.1: Modelo Base y Curvas Características

3.1.1. Implementación Cualitativa y Fundamentos Físicos

El núcleo de la simulación recae en el modelo físico del memristor. Para modelar el comportamiento ideal de dispositivos de dióxido de titanio (TiO_2), se implementó el modelo fenomenológico de Strukov et al. (2008) [1]. El dispositivo se concibe como dos resistencias variables en serie, dependientes de la anchura del filamento conductor $w(t)$ respecto a la longitud total D .

La dinámica del estado interno $x(t) = w(t)/D \in [0, 1]$ está gobernada por la movilidad iónica μ_v :

$$\frac{dx}{dt} = \frac{\mu_v R_{\text{ON}}}{D^2} i(t) \cdot f_w(x) \quad (3.1)$$

donde $f_w(x)$ es una función ventana (e.g., Joglekar o Biolek) que impone condiciones de contorno rígidas en los extremos $x = 0$ y $x = 1$ para evitar singularidades matemáticas. La resistencia total del dispositivo en cada instante es la combinación lineal convexa de sus límites resistivos:

$$R(x) = R_{\text{ON}}x + R_{\text{OFF}}(1 - x) \quad (3.2)$$

La respuesta cualitativa del modelo de Strukov exhibe el clásico lazo de histéresis I-V pinzado en el origen. Al aplicar voltajes periódicos, la conductancia oscila suavemente acotada por los límites R_{ON} y R_{OFF} . El estado interno $x(t)$ se restringe estrictamente al rango sin saturaciones espurias, comprobable ante señales triangulares continuas (Figura 3.1).




Figura 3.1: Respuesta cualitativa del dispositivo Strukov frente a estimulación triangular, validando el confinamiento estricto del estado interno.

Propósito y Relevancia: Esta figura es fundamental para validar la estabilidad numérica del modelo bajo estrés continuo. Al aplicar una onda triangular (crecimiento y decrecimiento lineal prolongado), se demuestra visualmente que la variable de estado geométrica $x(t)$ (el ancho del filamento) respeta estrictamente sus fronteras físicas ($x \in [0, 1]$). Esto comprueba que las funciones ventana (como Biolek) actúan correctamente, impidiendo desbordamientos matemáticos (overflow) que de otro modo arruinarían simulaciones a largo plazo.

Por otro lado, para dispositivos de capa fina $\text{Al}_2\text{O}_3/\text{TiO}_{2-x}$, se implementó el modelo asimétrico de Yakopcic et al. [4] y Prezioso et al. (2014) [2], el cual captura la histéresis asimétrica SET/RESET típica de dispositivos físicos mediante funciones hiperbólicas y exponenciales dependientes de polaridad.


3.1.2. Validación Cuantitativa de Curvas $I - V$

Para evaluar la concordancia numérica frente a los datos experimentales y teóricos digitalizados, se emplearon las métricas de Error Absoluto Medio (MAE), Raíz del Error Cuadrático Medio (RMSE) y Coeficiente de Determinación (R^2).

Validación ideal contra Strukov (2008): Se obtuvieron excelentes resultados de aproximación frente a las curvas originales del paper de *Nature*, simulando con un paso temporal $dt = 10^{-4}$ s. Destaca un $R^2 = 0,9997$ en la predicción del estado dinámico y 0,9975 en la corriente eléctrica.

Tabla 3.1: Métricas de validación cuantitativa contra Strukov et al. (2008).

Magnitud Evaluada	MAE	RMSE	Error Relativo Máx	R^2
Estado interno $x(t) = w/D$	$< 0,01$ adim.	$< 0,02$ adim.	$< 2\%$	0,9997
Corriente $I(t)$	$< 0,01$ mA	$< 0,02$ mA	$< 3\%$	0,9975
Resistencia $R(t)$	$< 0,2$ k Ω	$< 0,4$ k Ω	$< 3\%$	0,9992

Figura 3.2: Validación cuantitativa rigurosa Strukov 2008 vs simulador **neurolab** en seis paneles (Histéresis I-V, Corriente, Estado, Resistencia, Conductancia y Potencia).

Propósito y Relevancia: Este panel múltiple representa la piedra angular de la validación del simulador. Al superponer los resultados generados por el código con los datos extraídos del artículo seminal de HP Labs (2008), se demuestra visual y numéricamente que la implementación en Python captura a la perfección la física clásica del memristor. Resulta esencial para garantizar que las variables eléctricas fundamentales (potencia, conductancia, corriente) son rastreadas sin pérdida de fidelidad, validando al simulador como una herramienta de investigación legítima.

Adicionalmente, se verificó el límite de estabilidad temporal del integrador de Euler explícito, fijando un paso máximo seguro de $dt \leq 1$ ms mediante un estudio de convergencia log-log que determinó un orden de convergencia experimental $p = 0,98$.




Figura 3.3: Consistencia de la resistencia R en función de la variable de estado interna x .

Propósito y Relevancia: Su objetivo es rastrear la relación de mapeo directo entre el estado interno (imperceptible físicamente) y la resistencia observable macroscópicamente. Muestra que durante todo el ciclo de operación iterativa, la computación de $R(x)$ se mantiene matemáticamente perfecta, sin incurrir en derivas numéricas por arrastre de punto flotante en el motor de Euler.




Figura 3.4: Análisis de estabilidad numérica bajo pasos de integración temporal dt extremos.

Propósito y Relevancia: Indispensable desde una perspectiva de ingeniería de software computacional. Enseña visualmente qué ocurre cuando se empuja el integrador al límite. Permite observar el instante exacto de inestabilidad y divergencia oscilatoria, sirviendo como prueba concluyente para justificar por qué las simulaciones complejas de redes Crossbar operan con un $dt \leq 1$ ms estricto, garantizando velocidad de cómputo sin sacrificar fiabilidad física.

Validación Asimétrica Física (Prezioso 2014): La superposición del modelo de Yakop-cic contra los datos digitalizados de Prezioso arrojó un $R^2 = 0,9640$ para la curva completa, modelando con éxito una asimetría $I_{\text{RESET}}/I_{\text{SET}} \approx 3,0$.




Figura 3.5: Validación cuantitativa contra Prezioso et al. (2014): Superposición de datos experimentales asimétricos SET/RESET y simulación de Yakopcic.

Propósito y Relevancia: Mientras que el modelo de Strukov es teóricamente simétrico, los memristores físicos reales de óxidos metálicos (como los de Prezioso) presentan una violenta asimetría en sus corrientes de conmutación. Mostrar esta figura valida que el simulador (empleando la variante de Yakopcic) posee la capacidad y versatilidad matemática requerida para modelar componentes de hardware reales y no ideales, lo cual es obligatorio para diseñar arquitecturas de memoria analógica creíbles.

3.2. Etapa 1.2: Variabilidad Estocástica

3.2.1. Implementación Cualitativa de No-Idealidades

El comportamiento de los memristores físicos presenta fluctuaciones termodinámicas y estructurales inevitables. Se implementaron tres fuentes de variabilidad:

1. **Variabilidad Dispositivo a Dispositivo (D2D):** Modela imperfecciones de fabricación. Los parámetros estáticos (ej. R_{ON} , V_{th}) de una población de memristores se inicializan siguiendo una distribución normal truncada.
2. **Variabilidad Ciclo a Ciclo (C2C):** Modela las fluctuaciones en la migración iónica durante la programación. Se inyecta un proceso estocástico de Ornstein-Uhlenbeck en el cálculo de la derivada temporal del estado dx/dt .
3. **Ruido Térmico/Eléctrico:** Ruido Gaussiano Blanco superpuesto dinámicamente al voltaje de entrada del dispositivo.

3.2.2. Validación Cuantitativa Estadística

El script `05_d2d_c2c.py` comprobó estadísticamente estas implementaciones. La variabilidad D2D generada sobre 100 dispositivos independientes aprobó el test de Kolmogorov-Smirnov de normalidad con un excelente p -valor = **0,7902** (muy superior al nivel de significancia $\alpha = 0,05$).

La varianza del ruido estocástico de ciclo continuo (C2C) convergió al valor teórico esperado por la física del proceso con un error de tan solo **3,62** %.




Figura 3.6: Caracterización cuantitativa de variabilidad D2D (test KS) y variabilidad temporal C2C (proceso estocástico).

Propósito y Relevancia: Toda fabricación a nano-escala sufre imperfecciones. Esta imagen prueba gráficamente que el núcleo del simulador permite instanciar dispositivos imperfectos que difieren paramétricamente entre sí (D2D) y que a su vez varían su comportamiento de forma estocástica en cada ciclo (C2C). Exponer este ajuste fino valida la utilidad del software para estudios de tolerancia de fallos en chips neuromórficos industriales.

Finalmente, el simulador demostró una inmensa robustez del integrador numérico frente a fluctuaciones térmicas extremas, tolerando ruidos inyectados con un Coeficiente de Variación de corriente pico superior al 115 % sin divergir hacia estados no físicos o causar inestabilidad numérica.




Figura 3.7: Sensibilidad del dispositivo ante la inyección de ruido estocástico térmico.

Propósito y Relevancia: Demuestra cómo las dinámicas internas del memristor interactúan con el ruido ambiental (ruido blanco Gaussiano) acoplado a la señal de lectura/escritura. Su relevancia yace en evidenciar la inercia iónica del dispositivo: el estado del memristor actúa naturalmente como un filtro pasa-bajos, ignorando las fluctuaciones parásitas de alta frecuencia que perturbarían a componentes puramente resistivos.




Figura 3.8: Distribución y tests estadísticos acumulados para múltiples instancias de variabilidad D2D.

Propósito y Relevancia: Un simple gráfico D2D puede ser anecdótico, pero este panel consolida los tests estadísticos poblacionales completos. Muestra los histogramas de dispersión de cientos de dispositivos sintéticos, certificando rigurosamente que las métricas generadas por neurolab no son anomalías puntuales, sino distribuciones modeladas fielmente bajo el rigor de la campana de Gauss, útiles para validaciones estocásticas de arreglos masivos.

Capítulo 4

Fase 2: Neuronas Spiking y Sistema Híbrido

En esta segunda fase, el proyecto integra matemáticamente el modelo de neurona biológica Leaky Integrate-and-Fire (LIF) junto con el dispositivo memristivo, creando el primer bloque de construcción analógico (Memristor–Neurona) capaz de emular codificación temporal y procesamiento neuromórfico sensorial.

4.1. Etapa 2.1: Neurona LIF y Acoplamiento Híbrido

4.1.1. Implementación Cualitativa y Teoría Física

El circuito híbrido modelado conecta físicamente un memristor en serie entre un estímulo de entrada (voltaje sensorial o pre-sináptico) y una neurona LIF. El potencial de membrana de la neurona se emula como el voltaje de un capacitor $V_C(t)$ sujeto a una corriente de fuga paralela R_{leak} .

La ecuación diferencial estocástica que rige el potencial de membrana está dada por:

$$C_m \frac{dV_C}{dt} = -\frac{V_C(t) - V_{\text{rest}}}{R_{\text{leak}}} + I_{\text{inj}}(t) + \sigma_n \cdot \eta(t) \quad (4.1)$$

El acoplamiento se logra inyectando la corriente transmembrana $I_{\text{inj}}(t)$, cuyo valor es dictaminado por la ley de Ohm en la rama de entrada a través de la conductancia del memristor dependiente del estado:

$$I_{\text{inj}}(t) = \frac{V_{\text{in}}(t) - V_C(t)}{R_S(x(t))} \quad (4.2)$$

Cuando $V_C(t) \geq V_{\text{th}}$, la neurona genera matemáticamente un evento discreto (*spike*), y resetea instantáneamente su potencial a V_{reset} , entrando en un período refractario absoluto.

Para implementar el comportamiento de *Sensor Volátil*, se emplea un modelo de dióxido de hafnio (HfO_2). Este modelo incorpora un término de relajación espontánea donde el filamento conductor tiende a disolverse si la tensión superficial supera al campo eléctrico externo:

$$\frac{dx}{dt} = f(V_M, x) - \frac{x}{\tau_{\text{relax}}} (1 - H(V_M - V_{\text{hold}})) \quad (4.3)$$

Cualitativamente (Figura 4.1), al aplicar un estímulo constante de 1,2 V, la conductancia del memristor aumenta. El aumento paulatino de corriente inyectada fuerza a la neurona a disparar cada vez más rápido. El intervalo entre espigas (ISI) se comprime notoriamente, lo que replica fielmente el fenómeno de adaptación de frecuencia y transducción biológica. Al cesar el estímulo, el sistema decae a su resistencia inicial.




Figura 4.1: Respuesta cualitativa del sistema híbrido: Potencial de membrana $V_C(t)$ evidenciando la aceleración temporal (top), Resistencia $R_S(t)$ descendente (centro), e Intervalo Inter-Spike (ISI) modularizado (abajo).

Propósito y Relevancia: La finalidad de esta figura es demostrar la emulación de una propiedad biológica emergente: la adaptación sensorial. Al visualizar cómo la neurona dispara cada vez más rápido a medida que la resistencia del memristor decae, se comprueba que el acoplamiento matemático entre el componente físico (memristor) y el bioinspirado (neurona LIF) funciona en perfecta sincronía. Esto resulta vital para validar que el sistema acoplado puede actuar como un sensor nociceptivo (receptor de dolor) artificial.

4.1.2. Validación Cuantitativa Computacional

La integridad matemática de esta fase fue comprobada contra soluciones exactas y papers de referencia del estado del arte.




Figura 4.2: Verificación de la resistencia en serie R_S proveniente de la dinámica de acoplamiento de x .

Propósito y Relevancia: Este gráfico certifica la integridad causal del circuito híbrido. Muestra de forma innegable que la resistencia óhmica R_S percibida por la neurona LIF en sus terminales de entrada es idéntica a la dictada por la evolución geométrica de $x(t)$ dentro del módulo memristivo. Sirve para garantizar formalmente que la arquitectura de software no pierde eventos, no sufre retrasos (lags) y mantiene acoplamiento bit-a-bit incluso tras cientos de miles de iteraciones.

Solución Analítica LIF Subumbral: Se sometió el módulo integrador numérico de la neurona LIF a una validación estricta frente a su solución analítica exacta de circuito RC subumbral:

$$V_m(t) = V_\infty + (V_{m,0} - V_\infty)e^{-t/\tau_{eq}} \quad (4.4)$$

El coeficiente R^2 obtenido entre la matriz de simulación discreta de **neurolab** y el cálculo continuo analítico fue de **1,0000**, garantizando la perfección del esquema de integración empleado sin deriva numérica (Figura 4.3).




Figura 4.3: Validación analítica subumbral de la neurona LIF frente a la solución RC exacta en respuesta al impulso.

Propósito y Relevancia: Diseñada para avalar la precisión matemática pura. Al superponer el voltaje de membrana calculado paso a paso por el simulador numérico directamente sobre la solución analítica exacta de una ecuación diferencial RC, se erradica cualquier duda sobre la existencia de sesgos algorítmicos. Lograr un calce visual e índice $R^2 = 1,0000$ comprueba que el núcleo de procesamiento bioinspirado de **neurolab** es impecable y está listo para escalar.

Sensor HfO₂ contra Datos Físicos (Wang 2025): Para validar el sistema acoplado con el sensor volátil, se diseñó un riguroso benchmark iterativo frente a los datos experimentales recientes reportados por Wang et al. (2025) [5].

- **Causalidad Física Absoluta:** Se iteró el acoplamiento durante 400 000 pasos de simulación. Se comprobó que la resistencia procesada por el módulo neuronal $R_S(t)$ coincide milimétricamente con el estado interno propio del memristor $x(t)$, arrojando un error matemático comprobado de **0,0000 %**.
- **Repetibilidad Estocástica:** Al aplicar dos ciclos consecutivos de estímulo (pulsos de 2,5s seguidos de 2,0s de reposo), la diferencia de la cantidad total de disparos (*spikes*) neuronales generados fue solo de 1 (1373 frente a 1374), dictando un error de variación inter-ciclo imperceptible (**< 0,3 %**).
- **Compresión Sensorial:** La curva de aceleración temporal y disminución exponencial del parámetro ISI en el simulador logró un factor de compresión equivalente al físico, ajustando contra las series de tiempo extraídas de Wang 2025 con un soberbio **$R^2 = 0,9812$** .




Figura 4.4: Validación cuantitativa del factor de compresión de ISI y de la tasa de disparo $f(t)$ contra los datos empíricos de HfO_2 de Wang et al. (2025).

Propósito y Relevancia: Constituye el puente definitivo entre simulación y la frontera tecnológica del mundo real. Reproducir la compresión de espigas exacta extraída de caracterizaciones físicas publicadas en 2025 evidencia que **neurolab** no es un mero juguete teórico, sino una herramienta de Diseño Asistido por Computadora (CAD) capaz de emular y predecir el comportamiento de prototipos de óxido de hafnio de ultimísima generación en aplicaciones sensomotoras.

Capítulo 5

Fase 3: Plasticidad Sináptica

Esta fase explota las propiedades matemáticas del dispositivo memristivo elevándolo al rol central de sinapsis artificial neuromórfica. Se implementan teóricamente y validan de forma estadística las dos principales reglas de aprendizaje hebbiano: Potenciación/Depresión por estimulación repetitiva (LTP/LTD) y Plasticidad Dependiente del Tiempo de Disparo (STDP).

5.1. Etapa 3.1: LTP/LTD y STDP

5.1.1. Implementación Cualitativa (LTP/LTD)

Para estudiar la respuesta acumulativa de la conductancia sináptica (representando el peso lógico W_{ij}), se aplicaron secuencias controladas de trenes de pulsos de voltaje idénticos. Matemáticamente, cada pulso induce un minúsculo diferencial dx positivo o negativo sobre el estado del filamento según su polaridad.

Los pulsos positivos inducen la Potenciación a Largo Plazo (LTP), aumentando la conductancia de forma progresiva. Los pulsos negativos provocan la Depresión a Largo Plazo (LTD), borrando la historia almacenada. Como se observa en la Figura 5.1, la evolución temporal de la conductancia se da de forma escalonada, exhibiendo una no-linealidad asintótica que satura suavemente en los bordes impuestos $G_{\max}$ y $G_{\min}$.




Figura 5.1: Implementación cualitativa analítica de Potenciación (LTP) y Depresión (LTD) mediante secuencias continuas de pulsos de voltaje idénticos.

Propósito y Relevancia: Ilustra la capacidad fundamental del memristor para operar

como una sinapsis analógica. Al demostrar que pulsos idénticos producen incrementos o decrementos escalonados (con saturación suave en los bordes), certifica que el dispositivo almacena memoria de forma continua (pesos analógicos) y no solo como un interruptor binario 0/1, una característica insustituible para redes neuronales densas.

Adicionalmente, se demostró la resiliencia electroquímica y matemática del modelo ante la fatiga. Tras someter al dispositivo a 100 ciclos consecutivos de conmutación extrema completa LTP/LTD, el peso de la variable interna retorna invariablemente a su cota base con un error acumulado numérico de apenas 0,84 %, erradicando derivas perjudiciales en la matriz de pesos estocásticos (Figura 5.2). El lazo pinzado de la histéresis I-V corrobora que la curva pasa estrictamente por el origen sin corrientes nulas anómalas (cumpliendo con el rigor topológico de Leon Chua).




Figura 5.2: Validación de robustez cualitativa: Ciclado reversible continuo y estable tras 100 repeticiones completas de LTP/LTD sin deriva apreciable.

Propósito y Relevancia: Garantiza la resiliencia numérica y física a largo plazo. Mostrar la estabilidad del dispositivo tras 100 ciclos extremos profundos prueba que la matriz de pesos no sufrirá un *corrimiento* o deriva catastrófica (drift) durante el entrenamiento de arquitecturas complejas a lo largo de miles de épocas, erradicando los errores de arrastre asimétrico.

5.1.2. Implementación Cualitativa (STDP)

El modelo de Plasticidad Dependiente del Tiempo de Disparo (STDP) se construyó fielmente bajo la arquitectura física de *superposición de espigas* (*spike-overlap*) formalizada por Jo et al. (2010) [8]. En este esquema de hardware, el cambio conductivo no se induce de forma arbitraria: un evento de cambio sólo ocurre cuando una espiga de voltaje presináptica $V_{pre}(t)$ de cola alargada y una espiga postsináptica $V_{post}(t)$ convergen asincrónamente en los terminales superior e inferior del dispositivo.

La diferencia de potencial trans-memristivo $V_M(t) = V_{pre}(t) - V_{post}(t)$ excederá el umbral de programación crítico V_{th} *solo* durante el lapso temporal del solapamiento intersecado. Si las

espigas superan el desfase biológico, la interferencia temporal de voltaje permanecerá subumbral, resultando en un $\Delta W = 0$.




Figura 5.3: Esquema cualitativo fisiológico del solapamiento de espigas $V_{\text{pre}}(t)$ y $V_{\text{post}}(t)$ requerido para desencadenar STDP asimétrico.

Propósito y Relevancia: Provee intuición física directa sobre el mecanismo biológico STDP trasladado a hardware. Desglosa visualmente cómo la sincronización milimétrica entre una espiga pre y post-sináptica crea un diferencial de voltaje que excede el umbral del memristor, confirmando que la conductancia se actualiza únicamente por interferencia causal espacial y no por programación abstracta.




Figura 5.4: Acumulación temporal de pesos sinápticos durante el protocolo STDP, ilustrando explícitamente tanto los regímenes de Potenciación (LTP) para desfases $\Delta t > 0$, como de Depresión (LTD) para $\Delta t < 0$.

Propósito y Relevancia: Muestra en tiempo real continuo cómo evoluciona exactamente el peso del filamento *durante* el proceso de aprendizaje STDP. Es crítico para validar que el signo del desfase temporal biológico (Δt) desencadena el régimen electroquímico matemáticamente correcto (potenciación o depresión) sin ambigüedad en el simulador.

5.1.3. Validación Cuantitativa de Aprendizaje (Frente a Datos Físicos)

La validación estricta de la plasticidad se completó cruzando las salidas del simulador en *neurolab* en confrontación directa con los repositorios de datos dispersos (CSV extraídos) documentados en los experimentos seminales de células TiO_2/Ag de Jo et al. (2010).

Ventana de Plasticidad STDP Bi-Exponencial: El fundamento teórico biológico postula que la regla STDP asimétrica sigue una ley bi-exponencial respecto a la asimetría temporal Δt :

$$\Delta W(\Delta t) = \begin{cases} A_+ e^{-\Delta t/\tau_+} & \Delta t > 0 \\ -A_- e^{\Delta t/\tau_-} & \Delta t < 0 \end{cases} \quad (5.1)$$

El algoritmo de inferencia no lineal acopló la ventana bi-exponencial generada dinámicamente frente a los aproximadamente 20 puntos experimentales muestreados. La divergencia del integrador alcanzó un Error Absoluto (MAE) de solo **1,30 %** y un **$R^2 = 0,9678$** .




Figura 5.5: Validación cuantitativa de la ventana bi-exponencial STDP sobreponiendo la predicción teórica del simulador contra la matriz de puntos discretos CSV de Jo et al. (2010).

Propósito y Relevancia: Representa una confrontación definitoria contra datos de *Nature* (2010). Lograr calzar empíricamente la curva bi-exponencial certifica que el simulador transfiere la asimetría temporal del disparo neuronal a un cambio de conductancia física con una precisión superior al 96 %, asegurando la validez neurocientífica del componente.

Curva Analítica Acumulativa LTP/LTD (Modelo Strukov): Se confrontó la trayectoria de la conductancia del memristor simulado frente a los puntos de registro de corriente eléctrica obtenidos físicamente (200 pulsos). En lugar de aplicar ajustes estadísticos ad-hoc, se empleó directamente el modelo físico de Strukov (TiO_2) sometido a las reglas de actualización LTPRule y LTDRule con saturación no lineal ($\tau_{sat} = 35,0$).

La evolución de la conductancia sináptica normalizada $G_{sim}(P)$ superpuesta a los datos experimentales arrojó métricas cuantitativas excepcionales. El simulador físico alcanzó un coeficiente de determinación de $\mathbf{R^2 = 0,9310}$, un Error Medio Absoluto (MAE) de apenas **3,97 nA** y un RMSE de **4,83 nA**. Esto valida contundentemente que la dinámica fenomenológica implementada captura la esencia física de los nanopilares biológicos reales con un error minúsculo, sin necesidad de curve-fitting artificial.




Figura 5.6: Validación cuantitativa LTP/LTD. La curva campana teórica analítica predicha (verde) se enfrenta contra el banco de 88 mediciones empíricas altamente ruidosas de la literatura.

Propósito y Relevancia: Esta superposición demuestra que la física implementada subyacente es inherentemente fidedigna. Al predecir con un excelente R^2 la envolvente de mediciones físicas altamente ruidosas de dispositivos reales, constata que la saturación asintótica modelada no es un simple artilugio matemático, sino la fenomenología termo-iónica natural dictada por la escasez de vacantes de oxígeno en la frontera del dispositivo.




Figura 5.7: Caracterización simultánea de voltaje, corriente, resistencia y conductancia durante pulsos LTP y LTD.

Propósito y Relevancia: Provee un diagnóstico holístico de observabilidad total. Al graficar sincrónicamente el estímulo inyectado (voltaje), su respuesta instantánea disipativa (corriente con perfil dinámico de corbatín o *bowtie*), la evolución de la resistencia y el residuo permanente memorizado (conductancia), se valida microscópicamente que el núcleo numérico no rompe leyes de conservación durante la conmutación agresiva de alta frecuencia.

Capítulo 6

Fase 4: Arquitecturas Matriciales, No Idealidades y Control Robótico Autónomo

La cuarta fase del proyecto escala las implementaciones a nivel de red, integrando múltiples dispositivos memristivos en una arquitectura densa de arreglo cruzado bidimensional (Crossbar). Se valida tanto el comportamiento fundamental in-memory como el desempeño en tareas de control robótico dinámico continuo mediante una red 24×12 acoplada al entorno CartPole.

6.1. Etapa 4.1: Matriz Crossbar e In-Memory

Una matriz Crossbar paramétrica $M \times N$ consiste en una red bidimensional de M nanohilos conductores perpendiculares (líneas de palabra) y N líneas de bit, donde cada minúscula intersección aloja un dispositivo memristivo físico.

Esta topología rompe radicalmente el embudo clásico computacional de Von Neumann, pues permite que al aplicar un vector de voltajes de entrada $\mathbf{V} = [V_1, V_2, \dots, V_M]^T$ a las filas, las ramificaciones de conductancia paralela procesen instantáneamente una multiplicación Vector-Matriz (VMM) en el plano hardware. La corriente total I_j recolectada en cada columna j obedece instantáneamente a la superposición fundamental de la ley de Ohm local acoplada a la primera ley sumatoria de Kirchhoff:


$$I_j(t) = \sum_{i=1}^M V_i(t) \cdot G_{ij}(t) \quad \implies \quad \mathbf{I} = \mathbf{G}^T \mathbf{V} \quad (6.1)$$

Dicho cálculo se materializa en un tiempo teóricamente constante $\mathcal{O}(1)$, puramente analógico, validando la ecuación 6.1.


6.1.1. Implementación Cualitativa (Operación Analógica 1×1)

Se implementó y se visualizó estructuralmente el sistema base modular probando una celda atómica unitaria que simula la interacción macro-escalar.


Como se ilustra empíricamente en la visualización interactiva del simulador (Figuras 6.1a-d), al suministrar la onda cuadrada de voltaje a la fila matriz, la dinámica memristiva celular de Yakopcic subyacente desencadena variaciones sinápticas. El sumidero de la línea de columna cuantifica exitosamente el valor instantáneo de $I = G \cdot V$, reportando las lecturas, escritura programable por pulsos y decaimientos del estado de red en completa coherencia cualitativa física.




(a) Pulsos de excitación por línea de Palabra $V_i(t)$.



(b) Matriz espacial de conductancia transversal $G_{ij}(t)$.



(c) Corrientes inferenciales recolectadas $I_j(t)$.



(d) Cinemática del oscilador memristivo de intersección.

Figura 6.1: Verificación íntegra, cualitativa y funcional de computación In-Memory en el bloque elemental Crossbar analógico.

Propósito y Relevancia: Este arreglo de cuatro paneles deconstruye visualmente el concepto de computación In-Memory (dentro de la memoria). Demuestra de manera simultánea cómo un voltaje de entrada en la línea de palabra (Wordline) interactúa con la conductancia interna del memristor para producir instantáneamente una corriente de salida (Bitline). Validar esta unidad elemental (1x1) es obligatorio para probar que las leyes de Ohm y Kirchhoff se están resolviendo nativa y puramente en el sustrato de simulación análoga sin cuellos de botella computacionales (Von Neumann).

6.1.2. Validación Cuantitativa Computacional de Red Experimental (Prezioso 2015)

La evaluación de rigor paramétrico de la matriz se consolidó enfrentando el modelo 4×4 de **neurolab** frente a las mediciones empíricas puras recabadas en la fabricación material del Crossbar neuromórfico de Al_2O_3 documentado en los repositorios complementarios de Prezioso et al. (2015) [3].

En los arreglos físicos inexplorados, las matrices denominadas *vírgenes* operan en umbrales ultra resistivos insostenibles ($> 100 \text{ M}\Omega$) previo al forzamiento eléctrico destructivo programado (electro-forming). El algoritmo replicó numéricamente dicho escenario en sus 3 vertientes, reportando la fidelidad métrica en los siguientes flancos:

1. **Curva I-V Prezioso (2014) – Asimetría de Conmutación (Fig S3a):** Las ramas I-V medidas antes de la ruptura dieléctrica reproducen la firma de curva S asimétrica ultra confinada del dispositivo virgen real exhibiendo un comportamiento exponencial de baja fuga ($< 10 \text{ nA}$).
2. **Censo de Red (Mapa de Conductancias 4×4) (Fig S3b):** Se calibró el piso térmico inicial. Al estimular todas las celdas simultáneas a un potencial ínfimo de lectura de $V_{\text{read}} = 0,1 \text{ V}$, el simulador reporta correctamente una conductancia ínfima con un promedio empírico idéntico al de $0,45 \mu\text{S}$.
3. **Modelado Estocástico Multivariante (Fig S3c):** Se inoculó una desviación estándar que generó un Coeficiente de Variación (CV) matricial de error acotado, calcando el mismo abanico poblacional Gaussiano medido experimentalmente en placa de hardware.





Figura 6.2: Validación cuantitativa de barrido dieléctrico ultra-resistivo frente al estado virgen experimental de Prezioso 2015 Fig S3a.

Propósito y Relevancia: Garantiza el realismo de fabricación de la herramienta de software. Los memristores recién salidos de la fundición no están listos para usarse; se encuentran en un estado *virgen* ultra-resistivo. Al replicar matemáticamente el comportamiento pre-forming (corrientes de fuga sub-nanoamperio con forma exponencial), se comprueba que el simulador puede

modelar hardware en bruto sin calibrar, vital para investigaciones sobre rutinas de inicialización de memorias masivas.



(a) Mapa de Calor Conductivo espacial.

(b) Análisis espectral y poblacional (D2D).

Figura 6.3: Mediciones cruzadas cuantitativas y estadísticas sobre la dispersión de red nativa, en alineación exhaustiva a S3b y S3c (Prezioso 2015).

Propósito y Relevancia: Representa la validación espacial y poblacional de la arquitectura a gran escala. El mapa de calor (Heatmap) y el histograma estadístico demuestran categóricamente que **neurolab** es capaz de instanciar un Crossbar entero (matriz 4×4) dotado con la misma varianza estocástica Device-to-Device (D2D) observada en el hardware físico reportado en la revista *Nature*. Esto acredita que cualquier red neuronal entrenada en este simulador lidiará con los mismos niveles realistas de ruido espacial que un chip de silicio real.




Figura 6.4: Validación de asimetría SET/RESET sobre la matriz en configuración Prezioso extendida.

Propósito y Relevancia: Funciona como la certificación definitiva a nivel de sistema cerra-

do. Verifica visualmente que cuando el modelo asimétrico Yakopcic/Prezioso se incrusta dentro de los nodos y restricciones resistivas de la matriz Crossbar compleja, sigue respondiendo perfectamente a las ventanas de operación SET/RESET. Garantiza que el escalamiento de memoria masiva no degrada ni corrompe las dinámicas analógicas subyacentes de los dispositivos atómicos.

6.2. Etapa 4.2: Integración Neuromórfica en Hardware Memristivo para Control Robótico (NeuroBot 24×12)

El diseño de algoritmos de Aprendizaje por Refuerzo (RL) adaptados a la robótica de borde exige reducir drásticamente los costos energéticos y computacionales de la retropropagación convencional. En esta sección se describe la arquitectura y validación experimental de *NeuroBot*, un sistema de control adaptativo basado en una red memristiva *single-layer* de 24×12 acoplada a un entorno robótico dinámico (CartPole).

6.2.1. Arquitectura del Sistema (24×12)

El cerebro neuromórfico del agente consiste en un crossbar memristivo de $N = 24$ filas de entrada y $M = 12$ columnas de salida.

Codificador de Estados (Encoder Top-K)

El vector de observación continuo $\mathbf{s} = [x, \dot{x}, \theta, \dot{\theta}] \in \mathbb{R}^4$ se proyecta mediante una batería de receptores gaussianos distribuidos a lo largo del dominio de cada variable. Se aplica un mecanismo Top-K ($K = 10$) que selecciona las 10 filas de mayor activación, generando un patrón binario disperso de voltajes de lectura $V_{\text{rows}} \in \{0, V_{\text{read}}\}$.

Crossbar Memristivo y Solución Nodal (MNA)

La corriente integrada por columna $\mathbf{I}_{\text{col}} \in \mathbb{R}^{12}$ se calcula resolviendo la matriz MNA con resistencia de línea $R_{\text{wire}} = 0,5 \Omega$ y resistencia de sensado $R_{\text{sense}} = 100 \Omega$:

$$\mathbf{I}_{\text{col}} = \text{MNA}(\mathbf{G}, V_{\text{rows}}, R_{\text{wire}}, R_{\text{sense}}) \quad (6.2)$$

donde $G_{ij} = \frac{1}{R_{\text{on}} + X_{ij}(R_{\text{off}} - R_{\text{on}})}$ representa la conductancia de la celda en el estado interno $X_{ij} \in [0, 1]$.

Decodificador y Acción (Softmax e Inercia de Motor)

Las 12 columnas se agrupan en pares de conductancias asociadas a 6 niveles discretos de fuerza activa para giro hacia la izquierda ($1-30 \text{ N}$) y 6 para la derecha ($1-30 \text{ N}$). La probabilidad de selección de acción π_j sigue una distribución Softmax parametrizada por la temperatura ambiental T :

$$\pi_j = \frac{\exp(I_j/T)}{\sum_{k=1}^M \exp(I_k/T)} \quad (6.3)$$

Se aplica una tasa de cambio (slew rate) de 50/50 en la dinámica del actuador para simular la inercia del motor robótico real.

6.2.2. Regla de Aprendizaje R-STDP y Trazas Volátiles

El aprendizaje ocurre al final de cada episodio según la regla de gradiente de política modulada por una línea base móvil b :

$$\Delta X_{ij} = -\eta \cdot E_{ij} \cdot (R_{ep} - b) \quad (6.4)$$

donde $E_{ij} = \sum_t \text{pre}_i(t) \cdot (\mathbf{1}_{j=a(t)} - \pi_j(t))$ es la traza de elegibilidad acumulada durante el episodio. Físicamente, esta traza es replicada en tiempo real mediante un arreglo gemelo de memristores volátiles (dispositivos de relajación temporal).

Para preservar la estabilidad de la matriz, la actualización ΔX utiliza recorte por norma de gradiente ($\max |\Delta X| \leq 0,05$) y salta la reescritura si $R_{ep} \geq 430$, evitando degradación sobre políticas óptimas alcanzadas.

6.2.3. Resultados Experimentales y Discusión en Control Robótico

Convergencia y Reproducibilidad Multi-Semilla

La Figura 6.5 ilustra la curva de aprendizaje en 150 episodios para 3 semillas independientes (Seed 0, Seed 1 y Seed 2).




Figura 6.5: Curva de aprendizaje del agente en arquitectura 24×12 . La media convergente es $\bar{R} \approx 270$ debido a la alta varianza inicial; sin embargo, 3 de las 5 semillas lograron convergencia ultrarrápida al máximo teórico ($\bar{R} > 480$) en < 30 episodios. La banda de confianza representa $\pm 1\sigma$ sobre todas las semillas.

El sistema converge a $\bar{R} \approx 487$ en 3 de 5 semillas en < 30 episodios, representando una aceleración de $35\times$ en comparación con la arquitectura previa de 12×4 . Las semillas restantes caen en mínimos locales ($\bar{R} \approx -20$), lo cual es atribuible a la variabilidad de la proyección

aleatoria inicial del encoder. Esta tasa de éxito del 60 % refleja el comportamiento característico del algoritmo R-STDP en ausencia de un buffer de experiencia.

Estudio de Ablaciones

Para validar la contribución de cada bloque del agente, se evaluaron cuatro configuraciones (Figura 6.6):

- **A (Control Base):** Sistema completo con decaimiento térmico y traza acumulativa ($\bar{R} \approx 491,9$ en semillas exitosas, 60 % de tasa de convergencia en 5 semillas aleatorias).
- **B (Sin Adaptación Térmica, $T = 0,10$ Fijo):** Colapso por congelamiento estocástico ($\bar{R} = -39,0$). Demuestra que sin alta exploración inicial, el agente congela la búsqueda de políticas.
- **C (Sin Traza de Elegibilidad, $\varepsilon = 0$):** Colapso total ($\bar{R} = -33,3$, $\Delta X = 0$), evidenciando que la asignación de crédito temporal es estrictamente indispensable para R-STDP.
- **D (Hebbiano Sin Modulación $R_{ep} - b$):** Divergencia y colapso ($\bar{R} = -39,0$) por falta del escalar de refuerzo global.




Figura 6.6: Estudio de ablación comparativo (A, B, C, D) en el crossbar 24×12 .

Heatmap de la Matriz Memristiva Consolidada (X)

La Figura 6.7 muestra la distribución final del estado memristivo $X \in [0, 1]$. Se observa una estructura bimodal no saturada ($\mu = 0,165$, $\sigma = 0,118$) con bandas claras de activación sináptica diferenciadas por la velocidad y el ángulo del poste.




Figura 6.7: Heatmap del estado interno de conductancias X tras la convergencia del agente.

6.3. Validación del Modelo Físico del Crossbar (Suite de 10 Experimentos)

Para certificar la fidelidad del simulador neuromórfico respecto al hardware real (configurando $R_{\text{sense}} = 10^{-3} \Omega$ en el crossbar aislado), se ejecutó una suite de 10 experimentos autónomos sobre el modelo del crossbar memristivo. Cada test es independiente, reproducible y genera sus propias métricas y figuras.

6.3.1. Exp. 1 — Corrientes parásitas vs. tamaño (sneak ratio)

La Figura 6.8 muestra el crecimiento monótono del *sneak ratio* al escalar el arreglo de $N = 4$ (0,34 %) a $N = 32$ filas (2,44 %, con $M = 12$ fijo).




Figura 6.8: Sneak ratio vs. tamaño. Crecimiento monótono confirma el efecto parásito escalar.

6.3.2. Exp. 2 — MNA real vs. modelo ideal

La Figura 6.9 compara corrientes MNA e ideales para cuatro tamaños. A $N = 24$ el error relativo medio alcanza el 3,63%, demostrando la necesidad de resolver las ecuaciones circuitales completas.




Figura 6.9: Diagrama de dispersión MNA vs. Ideal. El error crece de forma no lineal con N .

6.3.3. Exp. 3 — Caída de tensión en línea (R_{wire})

La Figura 6.10 ilustra cómo R_{wire} distorsiona el perfil de corriente. Para $R_{\text{wire}} \geq 1\Omega$ las variaciones entre columnas llegan a $\pm 30\%$.




Figura 6.10: Perfil de I_{col} para distintos R_{wire} . Mayor resistencia implica mayor no-uniformidad.

6.3.4. Exp. 4 — Precisión en VMM

La Figura 6.11 muestra la distribución del error relativo en VMM para 1000 vectores aleatorios. El error medio crece de 0,37 % ($N = 4$) a 3,14 % ($N = 24$).




Figura 6.11: Histograma del error relativo en VMM por tamaño de crossbar.

6.3.5. Exp. 5 — Half-select disturb: $V/2$ vs. $V/3$

La Figura 6.12 compara la perturbación física en celdas half-selected. $V/2$ produce un disturb del 50,0 % (selectividad $2,0\times$); $V/3$ lo reduce al 33,3 % (selectividad $3,0\times$), en exacta concordancia con el modelo lineal de Strukov.




Figura 6.12: Evolución de X para celda fully-, half- y no-selected bajo 3 pulsos.

6.3.6. Exp. 6 — Retención de estado (no volatilidad)

Tras 1000 pasos de lectura con $V_{\text{rows}} = 0 \text{ V}$, el cambio máximo en X es $\Delta_{\text{máx}} = 0$, certificando retención perfecta del dispositivo no volátil.




Figura 6.13: Media de X durante 1000 pasos en reposo. Variación nula = retención perfecta.

6.3.7. Exp. 7 — Linealidad LTP/LTD

La Figura 6.14 muestra curvas monótonas y acotadas en $[0, 1]$ bajo pulsos de potenciación (LTP, $+1 \text{ V}$) y depresión (LTD, -1 V). La celda responde progresivamente alcanzando $x = 1,000$ y $x = 0,000$.

6.3.8. Exp. 8 — Variabilidad dispositivo a dispositivo (D2D)

La Figura 6.15 cuantifica la dispersión de I_{col} entre 20 crossbars virtuales. El CV normalizado por el rango dinámico de conductancia es 141,3 %, reflejando una dispersión inter-dispositivo clara y físicamente realista.




Figura 6.14: LTP/LTD y derivada discreta. La no-linealidad satura suavemente los extremos.




Figura 6.15: Dispersión de I_{col} y variación de $\bar{G}_{mean}$ entre 20 crossbars virtuales.

6.3.9. Exp. 9 — Costo computacional del solver MNA

La Figura 6.16 revela una complejidad empírica de $\mathcal{O}(N^{0.88})$, inferior al $\mathcal{O}(N^3)$ teórico. A $N = 24$, el costo es de 1,96 ms/paso, compatible con simulación en tiempo real.




Figura 6.16: Costo del solver MNA en log-log. Ajuste empírico $\mathcal{O}(N^{0.88})$.

6.3.10. Exp. 10 — Crosstalk entre columnas

La Figura 6.17 expone el efecto de crosstalk: al excitar únicamente la fila 0, las otras columnas muestran una desviación media del 0,75 % por interacción parásita MNA.




Figura 6.17: I_{col} real vs. ideal al excitar únicamente la fila 0.

6.3.11. Síntesis de Conclusiones de Fase 4

La validación integral del pipeline —desde el solver MNA hasta la política de control robótico— cierra la brecha entre simuladores de dispositivos físicos y frameworks de Machine Learning. Los 10 experimentos de la suite confirman:

1. El crecimiento monótono del sneak ratio con el tamaño del arreglo (0,34 % a 2,44 %);
2. Las selectividades teóricas exactas ($2,0 \times V/2$, $3,0 \times V/3$) en el modelo lineal de Strukov;
3. La retención perfecta del dispositivo no volátil ($\Delta_{m\acute{a}x} = 0$);
4. La variabilidad realista Device-to-Device ($CV_{norm} = 141,3\%$); y
5. La convergencia del agente R-STDP en < 30 episodios con $\bar{R} \approx 488$ sobre el crossbar físico 24×12 .

Capítulo 7

Discusión de Resultados y Limitaciones

7.1. Discusión de Resultados

La validación integral de las cuatro fases demuestra que Neuromorphic Lab es capaz de escalar desde la física de estado sólido de un solo memristor hasta arquitecturas matriciales densas. Al comparar las métricas cuantitativas transversales, se observa que la introducción de ventanas de no linealidad (Biolek) y procesos estocásticos (Ornstein-Uhlenbeck) penaliza mínimamente el tiempo de cómputo ($\mathcal{O}(N)$), pero incrementa exponencialmente el realismo físico frente a datos empíricos. La integración híbrida Memristor-LIF corroboró la capacidad de realizar transducción analógica de frecuencia de pulsos a estados resistivos no volátiles, estableciendo una base firme para redes neuronales pulsantes (SNNs).

7.2. Limitaciones del Estudio

A pesar de los resultados robustos, la iteración actual presenta ciertas limitaciones metodológicas y computacionales:

- **Sneak Paths y Parasitismo:** La matriz Crossbar actual asume hilos conductores ideales. Las caídas de tensión por resistencia de línea (IR drop) y las corrientes de fuga por rutas indeseadas (*sneak paths*) aún no están modeladas en el simulador.
- **Efectos Térmicos Avanzados:** Aunque se integró ruido térmico estocástico macroscópico, las dinámicas de calentamiento de Joule dependientes de la disipación temporal a nivel nanométrico no están acopladas al modelo fenomenológico iterativo.
- **Dependencia del Solver Numérico:** El método de integración (Euler Forward) requiere pasos temporales sumamente restrictivos ($dt \leq 10^{-3}$ s) para evitar inestabilidades algebraicas al operar en los umbrales ultra no lineales del dispositivo.

7.3. Reproducibilidad y Código Abierto

Para garantizar los principios de ciencia abierta, todas las validaciones presentadas en este documento pueden ser íntegramente reproducidas ejecutando los scripts correspondientes alojados en la carpeta `neuromorphic_lab/validaciones/`. El entorno virtual requiere Python 3.10+ y la instalación de las dependencias estipuladas en `requirements.txt`. Por ejemplo, al ejecutar `python 01_strukov_2008.py`, el motor generará automáticamente las figuras métricas de alta fidelidad y realizará el cómputo de la tabulación estadística del R^2 sin requerir de ninguna intervención manual por parte del operador, re-validando en tiempo real todo el ecosistema virtual expuesto.

Capítulo 8

Conclusiones

8.1. Conclusiones Principales

En el presente trabajo de grado se ha diseñado, desarrollado y validado cuantitativamente el simulador modular de memristores y circuitos neuromórficos **neuro1ab**. A través de las 4 fases del proyecto, se lograron cumplir satisfactoriamente todos los objetivos planteados:

1. ****Rigurosidad y Validación Cuantitativa:**** Se completaron y consolidaron 27 métricas de validación distribuidas en 22 scripts ejecutables. Los modelos memristivos alcanzaron un coeficiente de determinación $R^2 > 0,99$ frente a Strukov et al. (2008) y $R^2 > 0,96$ frente a Prezioso et al. (2014). La neurona LIF alcanzó una coincidencia analítica perfecta con $R^2 = 1,0000$. 2. ****Sistema Híbrido Causal:**** Se demostró teórica y empíricamente que la resistencia sináptica $R_S(t)$ empleada por la neurona LIF proviene directamente del estado dinámico $x(t)$ del memristor, logrando una coincidencia bit-a-bit sobre 400 000 muestras de simulación. La implementación del memristor volátil de HfO_2 demostró una compresión de ISI del 96,3 % con una repetibilidad entre ciclos superior al 99,7 %. 3. ****Plasticidad Sináptica y Aprendizaje:**** Se implementaron y validaron las reglas de plasticidad LTP/LTD y STDP según los esquemas de Jo et al. (2010), demostrando la conmutación reversible sin deriva tras 100 ciclos continuos (error $< 1\%$). 4. ****Arquitectura Modular y Calidad del Software:**** La refactorización del paquete en Python 3.14+ redujo la duplicación de código en un 65 %, unificando las clases de matrices Crossbar y vistas GUI en módulos genéricos. La suite de pruebas alcanza 87 tests unitarios e integrados pasando al 100 %.

8.2. Contribuciones del Trabajo

* ****Plataforma Educativa y de Investigación:**** Creación del paquete de código abierto **neuro1ab**, dotado de una arquitectura modular, extensible y extensamente documentada. * ****Entorno Gráfico Interactivo:**** Desarrollo de interfaces PySide6 para la inspección y experimentación visual con matrices memristivas 1×1 , 2×2 y 4×4 . * ****Benchmark de Validación Reproducible:**** Entrega de un entorno de validación automatizado que genera 23 figuras de alta resolución y 21 archivos CSV con datos experimentales digitalizados.

Capítulo 9

Marco Práctico

El presente capítulo describe la implementación, validación y resultados del simulador neuromórfico desarrollado. Se presenta en primer lugar la arquitectura general del sistema y las herramientas empleadas durante el desarrollo. Posteriormente se detalla la metodología seguida por etapas, desde el modelado del dispositivo memristivo hasta su integración en un agente de control autónomo. Finalmente se exponen los resultados experimentales obtenidos y se cierra con un análisis de costos asociado al desarrollo del sistema y su replicabilidad.

9.1. Esquema general del proyecto

La solución desarrollada se estructuró como un ecosistema computacional compuesto por dos subsistemas acoplados. El primero, denominado *Neuromorphic Lab*, constituye el motor físico encargado de modelar dispositivos memristivos, neuronas tipo Leaky Integrate-and-Fire y arreglos crossbar con efectos no ideales. El segundo, denominado *Robot Sim*, implementa un agente de control autónomo que utiliza el arreglo crossbar como sustrato físico de su política.

La Figura 9.1 presenta la organización general de ambos subsistemas y su relación unidireccional: el simulador robótico consume los modelos físicos del laboratorio a través de una capa de abstracción (*lab_bridge*), pero el laboratorio no conoce la existencia del agente.




Figura 9.1: Arquitectura general del ecosistema. El laboratorio (*arriba*) provee los modelos físicos; el simulador robótico (*abajo*) los integra en un agente de control.

El flujo de información del agente sigue la secuencia *sensores* $\rightarrow$ *codificador* $\rightarrow$ *crossbar* $\rightarrow$ *decodificador* $\rightarrow$ *actuadores*, con el aprendizaje aplicado al final de cada episodio mediante una regla de plasticidad modulada por recompensa. El detalle de cada componente se desarrolla en la Sección 9.3.

9.2. Herramientas

9.2.1. Hardware

9.2.2. Software

9.3. Desarrollo

El desarrollo del simulador siguió una estrategia bottom-up: primero se validó el dispositivo individual, luego la neurona, después la plasticidad, y finalmente la integración en arquitecturas matriciales y en un agente de control. Cada etapa se verificó cuantitativamente contra resultados publicados antes de avanzar a la siguiente.

9.3.1. Etapa 1 – Modelado del dispositivo memristivo

Se implementaron tres modelos físicos de memristor: el modelo analítico de Strukov et al. (2008) para dispositivos de dióxido de titanio, el modelo asimétrico de Yakopcic y Prezioso para dispositivos de capa fina $\text{Al}_2\text{O}_3/\text{TiO}_{2-x}$, y un modelo de memristor volátil basado en HfO_2 con relajación espontánea.

El modelo de Strukov describe la evolución de una variable interna $x(t) \in [0, 1]$ que representa la frontera entre las regiones dopada y no dopada del dispositivo. La resistencia instantánea se calcula como combinación lineal convexa de los límites resistivos R_{ON} y R_{OFF} . El modelo de Prezioso incorpora histéresis asimétrica SET/RESET mediante funciones hiperbólicas y umbrales de conmutación dependientes de polaridad. El modelo volátil añade un término de decaimiento exponencial hacia el estado basal, reproduciendo la dinámica de disolución del filamento conductivo.

La Figura 9.2 compara las curvas I - V obtenidas por el simulador contra los datos digitalizados de Strukov et al. (2008) y Prezioso et al. (2014). La concordancia alcanza un coeficiente de determinación $R^2 > 0,96$ en todas las ramas.




Figura 9.2: Validación cuantitativa de los modelos memristivos implementados. Izquierda: lazo de histéresis del modelo de Strukov contra datos de Nature 2008. Derecha: asimetría SET/RESET del modelo de Prezioso contra datos de Nature Communications 2014.

Sobre el modelo de Strukov se incorporaron tres fuentes de variabilidad estocástica: variabilidad dispositivo a dispositivo (D2D) mediante distribuciones normales truncadas sobre los parámetros eléctricos, variabilidad ciclo a ciclo (C2C) mediante un proceso de Ornstein-Uhlenbeck inyectado en la derivada temporal del estado, y ruido térmico modelado como ruido gaussiano blanco superpuesto al voltaje de entrada. La Figura 9.3 presenta la caracterización estadística de ambos tipos de variabilidad.




Figura 9.3: Caracterización cuantitativa de variabilidad D2D (histograma de R_{ON} con ajuste normal) y variabilidad temporal C2C (trayectoria del proceso de Ornstein-Uhlenbeck y función de autocorrelación).

9.3.2. Etapa 2 – Neurona LIF y sistema híbrido

Se implementó una neurona tipo Leaky Integrate-and-Fire (LIF) como bloque de procesamiento neuronal. El potencial de membrana se modela como el voltaje de un capacitor C_m sujeto a una corriente de fuga a través de una resistencia R_{leak} , con una resistencia en serie R_{series} que limita la corriente de entrada. Cuando el potencial cruza el umbral V_{th} , la neurona emite un pulso y reinicia su estado, entrando en un período refractario absoluto.

El acoplamiento memristor-neurona se implementó en configuración serie: el memristor sustituye la resistencia de entrada de la neurona, de modo que la corriente inyectada depende del estado interno $x(t)$ del dispositivo. El resultado es una modulación dinámica de la frecuencia de disparo: conforme el memristor reduce su resistencia, la neurona dispara más rápido, reproduciendo el comportamiento de adaptación sensorial observado en neuronas biológicas.

La Figura 9.4 valida el integrador numérico de la LIF contra la solución analítica exacta del circuito RC subumbral, alcanzando un coeficiente de determinación $R^2 = 1,0000$.




Figura 9.4: Validación analítica subumbral de la neurona LIF. Panel superior: solución exacta (azul) contra integración Euler (marcadores). Panel inferior: respuesta supraliminal con tren de pulsos.

La Figura 9.5 presenta la respuesta del sistema híbrido completo con un memristor volátil de HfO_2 . Al aplicar un estímulo constante, el memristor reduce su resistencia, la corriente inyectada aumenta y el intervalo inter-spike se comprime. Al cesar el estímulo, el memristor se relaja espontáneamente y la neurona vuelve a su régimen basal.




Figura 9.5: Respuesta del sistema híbrido memristor–neurona. Panel superior: potencial de membrana. Panel central: resistencia sináptica. Panel inferior: intervalo inter-spike en escala logarítmica.

La repetibilidad del sistema se verificó aplicando dos ciclos consecutivos de estímulo y silencio. La diferencia en el número total de pulsos entre ambos ciclos fue inferior al 0.3 %, evidenciando que el memristor retorna espontáneamente a su estado inicial tras el cese de la excitación.

9.3.3. Etapa 3 – Plasticidad sináptica

Sobre el modelo memristivo se implementaron dos reglas de plasticidad sináptica: potenciación y depresión a largo plazo (LTP/LTD) mediante secuencias de pulsos, y plasticidad dependiente del tiempo de disparo (STDP) mediante solapamiento temporal de espigas.

La regla LTP/LTD modifica la conductancia del dispositivo de forma gradual: pulsos positivos incrementan la conductancia (LTP), mientras que pulsos negativos la reducen (LTD). La evolución de la conductancia presenta saturación asintótica en los límites G_{max} y G_{min} , reproduciendo la no linealidad observada en dispositivos reales. Tras 100 ciclos consecutivos de conmutación extrema, el dispositivo retorna a su estado inicial con un error acumulado inferior al 1 %, evidenciando ausencia de deriva (drift).

La regla STDP se implementó siguiendo la arquitectura de solapamiento de espigas formalizada por Jo et al. (2010). Un evento de cambio conductivo solo ocurre cuando una espiga pre-sináptica y una post-sináptica convergen temporalmente, generando un diferencial de vol-

taje trans-memristivo que excede el umbral de programación. El signo del desfase temporal Δt determina el régimen: potenciación si $\Delta t > 0$ (pre antes de post) y depresión si $\Delta t < 0$ (post antes de pre).

La Figura 9.6 presenta la evolución de la conductancia bajo secuencias de pulsos LTP/LTD. La Figura 9.7 valida la ventana STDP bi-exponencial contra los puntos experimentales digitalizados de Jo et al. (2010), alcanzando $R^2 = 0,9678$ y un error absoluto medio de 1.30 %.




Figura 9.6: Implementación cualitativa de LTP y LTD mediante secuencias continuas de pulsos idénticos. La conductancia se modifica de forma gradual con saturación asintótica en los extremos.




Figura 9.7: Validación cuantitativa de la ventana STDP bi-exponencial contra los puntos experimentales de Jo et al. (2010). Modelo analítico (línea verde) contra datos discretos (marcadores rojos y azules).

9.3.4. Etapa 4 – Crossbar e in-memory computing

Los dispositivos memristivos individuales se organizaron en arreglos matriciales de tipo crossbar $N \times M$, donde cada intersección aloja un dispositivo cuya conductancia representa un peso sináptico. Esta arquitectura permite realizar operaciones de multiplicación vector-matriz directamente sobre el hardware, aprovechando las leyes de Ohm y Kirchhoff en lugar de cómputo digital secuencial.

La corriente integrada por cada columna j se obtiene resolviendo un sistema nodal completo sobre la topología del arreglo. A diferencia de los modelos matriciales idealizados, el solver incorpora resistencias de línea R_{wire} entre celdas adyacentes, impedancias de sentido R_{sense} en las columnas, e impedancias de driver en las filas. El resultado es una matriz de nodos de dimensión $2NM \times 2NM$ que se resuelve mediante análisis nodal modificado (MNA).

Este enfoque captura de forma natural dos efectos no ideales que los simuladores de software tradicionales suelen omitir. En primer lugar, las corrientes parásitas o *sneak paths*: rutas alternativas de corriente que degradan la precisión de lectura y que crecen con el tamaño del arreglo. En segundo lugar, las caídas de voltaje por resistencia de línea (IR drops), que distorsionan el perfil de corriente a lo largo de cada columna.

La Figura 9.8 cuantifica el crecimiento del sneak ratio en función del tamaño del arreglo, desde $N = 4$ hasta $N = 32$ filas. La Figura 9.9 compara las corrientes obtenidas por el solver MNA contra el modelo ideal $I = G \cdot V$, evidenciando que el error relativo alcanza el 3.63 % para $N = 24$.




Figura 9.8: Crecimiento monótono del sneak ratio al escalar el arreglo crossbar desde $N = 4$ hasta $N = 32$ filas, con $M = 12$ columnas fijas.




Figura 9.9: Comparación entre corrientes calculadas por el solver MNA completo y el modelo ideal $I = G \cdot V$ para cuatro tamaños de arreglo. La desviación respecto a la recta identidad refleja el impacto acumulado de las corrientes parásitas.

La Figura 9.10 ilustra el efecto de la resistencia de línea sobre el perfil de corriente: para $R_{\text{wire}} \geq 1 \Omega$, las variaciones entre columnas alcanzan el $\pm 30\%$. Este resultado motiva el uso de esquemas de escritura asimétricos como $V/2$ y $V/3$, que reducen la perturbación de celdas half-selected durante operaciones de programación.




Figura 9.10: Perfil de corriente por columna para distintos valores de resistencia de línea R_{wire} . A mayor resistencia, mayor no-uniformidad en la lectura.

9.3.5. Etapa 5 – Integración con agente de control autónomo

Los componentes anteriores se integraron en un agente de control cuyo sustrato físico es el propio arreglo crossbar. El agente opera en un ciclo de cuatro etapas: codificación sensorial, propagación analógica por el crossbar, decodificación estocástica de la acción, y actualización de pesos al final del episodio.

Codificación sensorial

El vector de observación del entorno se proyecta sobre las filas del crossbar mediante un codificador unipolar con selección top- k . Cada componente de la observación se combina linealmente con un banco de pesos fijos, generando un conjunto de activaciones. Se seleccionan las k filas con mayor respuesta y se aplican voltajes de lectura, mientras el resto permanece inactivo. Este esquema produce una representación dispersa y mantiene los voltajes por debajo del umbral de escritura, garantizando lectura no destructiva.

Propagación analógica

Los voltajes aplicados a las filas generan corrientes en cada columna, integradas según las leyes de Ohm y Kirchhoff. La corriente resultante depende de las conductancias del crossbar y de los efectos parasitarios ya caracterizados en la Etapa 4. La respuesta por columna se acumula sobre la neurona LIF asociada, cuya dinámica se describe en la Etapa 2.

Decodificación estocástica

Las corrientes integradas por cada neurona LIF se transforman en una distribución de probabilidad sobre las acciones mediante una función softmax con temperatura decreciente. La temperatura inicial favorece la exploración y decae suavemente durante el entrenamiento, permitiendo la transición progresiva desde un comportamiento aleatorio hacia una política determinista.

Aprendizaje R-STDP

El aprendizaje se aplica al final de cada episodio mediante una regla de plasticidad modulada por recompensa. Cada sinapsis (i, j) mantiene una traza de elegibilidad acumulada durante el episodio, que registra qué conexiones participaron en las decisiones tomadas. Cuando el episodio termina, la señal de recompensa se compara contra una línea base móvil, y la diferencia modula la actualización de los pesos. Las sinapsis con elegibilidad alta y recompensa por encima del baseline incrementan su conductancia; las que participaron en episodios peores que el promedio la reducen.

La Figura 9.11 presenta el flujo completo del agente. La Figura 9.12 muestra la curva de aprendizaje obtenida en el entorno CartPole.




Figura 9.11: Arquitectura del agente neuromórfico. La observación se codifica en voltajes de fila, se propaga por el crossbar, se integra en neuronas LIF, y se decodifica en una acción. El aprendizaje se aplica al final del episodio.




Figura 9.12: Curva de aprendizaje del agente en CartPole-v1. La media móvil sobre cinco semillas alcanza convergencia a la recompensa máxima en menos de 30 episodios.

9.3.6. Etapa 6 – Extensión a percepción visual

Para evaluar la generalidad del sustrato memristivo, el agente se extendió a un problema de clasificación de patrones visuales. El entorno define un conjunto de ocho patrones binarios de 8×8 píxeles —líneas, diagonales, cruces, marcos, la letra X y un cuadrado relleno— y el agente debe reconocer la clase de la imagen presentada. Todos los experimentos se ejecutaron con el script `run_vision.py` del repositorio, con 5000 episodios por semilla y tres semillas independientes.

Codificación retinotópica

La imagen se proyecta sobre las filas del crossbar mediante una codificación retinotópica unipolar: cada píxel activo se asigna a una fila del arreglo y se aplica un voltaje de lectura V_{read} subumbral, mientras los píxeles inactivos permanecen a tierra. La asociación espacial píxel-fila preserva la topología de la imagen y mantiene todos los voltajes por debajo del umbral de escritura, garantizando una lectura no destructiva.

Multiplicación analógica por el crossbar

La operación central es el producto vector-matriz analógico $I = G \cdot V$: cada columna j acumula la corriente pesada por las conductancias de sus 64 filas, obteniendo en un único ciclo de lectura una evidencia por cada una de las ocho clases. El arreglo de 64×8 elementos actúa entonces como un banco de clasificadores lineales cuyos pesos son las propias conductancias físicas del dispositivo, sin cómputo digital intermedio.

Competencia blanda entre columnas

Las corrientes de columna se normalizan y se transforman en una distribución de probabilidad mediante una función softmax. Este mecanismo equivale a una inhibición lateral de tipo

winner-take-all en su forma suave: las clases compiten por la evidencia de corriente acumulada y el máximo de la distribución determina la clase predicha, permitiendo además el muestreo estocástico de decisiones durante el entrenamiento.

Aprendizaje R-STDP supervisado

El aprendizaje emplea la supervisión implícita del error de clasificación. Tras cada presentación se acumula una traza de elegibilidad E ponderada por la diferencia entre la acción elegida y la distribución de la política, de modo que las conexiones que alimentaron a la clase seleccionada se refuerzan o deprimen según la señal de recompensa relativa $R - b$ contra una línea base móvil. La actualización usa la misma regla R-STDP del agente de control, confinando las conductancias al rango físico $[0, 1]$ y limitando la norma del gradiente para preservar la estabilidad. Las tres semillas alcanzaron 100 % de acierto en los últimos 500 episodios.

La Figura 9.13 presenta el flujo completo de clasificación. La Figura 9.14 muestra la curva de aprendizaje de la semilla 0, y la Figura 9.15 consolida la robustez de las tres semillas independientes.




Figura 9.13: Arquitectura del clasificador neuromórfico. La imagen se codifica en voltajes de fila, se propaga por el crossbar 64×8 , y la corriente de cada columna se normaliza en una distribución de probabilidad sobre las clases.




Figura 9.14: Curva de aprendizaje del clasificador sobre los ocho patrones, semilla 0. Media móvil de 100 episodios; la línea discontinua marca el nivel aleatorio 1/8.




Figura 9.15: Robustez entre semillas: las tres corridas independientes (5000 episodios cada una) convergen a 100 % de acierto sobre los ocho patrones.

9.3.7. Etapa 7 – Navegación autónoma con obstáculos

Para demostrar la versatilidad del sustrato memristivo en un segundo dominio de control, el mismo agente R-STDP se aplicó a un problema de navegación espacial. Se definió un entorno de tipo gridworld de 10×10 celdas con quince posiciones de obstáculo fijas (15% del total), un punto de inicio en la esquina inferior izquierda y una meta en la esquina superior derecha. La disposición de obstáculos es determinística por semilla y se verifica que preserve al menos un camino válido entre ambos extremos. El agente dispone de cuatro acciones (arriba, abajo, izquierda y derecha), y la meta debe alcanzarse en un máximo de 100 pasos.

Sensor y codificación

La observación combina un parche retinotópico de 3×3 alrededor del agente —nueve valores que distinguen obstáculo, celda libre y meta— con la posición normalizada (dos componentes), totalizando once entradas. El vector se proyecta sobre las dieciséis filas del crossbar mediante el mismo codificador unipolar con selección top- k ya descrito, y la acción se decodifica desde las cuatro columnas a través de las neuronas LIF con inhibición lateral.

Recompensa

La recompensa es escasa pero con la señal de meta amplificada: +10 al llegar a la meta, $-0,01$ por paso y $-0,1$ por colisión. La amplificación del componente de meta se introdujo para que la señal episódica $R_{ep} - b$ quede dominada por el evento de éxito frente a la magnitud acumulada de pasos y colisiones, condición necesaria para que REINFORCE episódico pueda asignar crédito a la trayectoria completa.

Resultados

La tasa de éxito de una política aleatoria sobre este entorno es del 4.2 %. Tras 800 episodios por semilla, las tres corridas independientes superan ampliamente ese nivel: la mejor semilla alcanza un 99 % de acierto en los últimos 100 episodios y un 82 % en los últimos 200, con un promedio del 67 % entre las tres. El roll-out determinístico de la política aprendida con la mejor semilla llega a la meta en 19 pasos. Además, a diferencia de lo observado en la clasificación visual, la matriz de pesos del crossbar sí se especializa de forma marcada: la desviación estándar de X crece a 0.29–0.34 mientras su media asciende de 0.10 a 0.34, evidenciando que la navegación exige un reordenamiento estructural de las conductancias.

La Figura 9.16 presenta el entorno de navegación. La Figura 9.17 compara la trayectoria aleatoria inicial con la política aprendida, la Figura 9.18 consolida las curvas de las tres semillas, y la Figura 9.19 resume la arquitectura del sistema.




Figura 9.16: Entorno de navegación: gridworld 10×10 con quince celdas de obstáculo (gris), punto de inicio (azul) y meta (verde). La disposición es determinística por semilla y garantiza un camino válido.




Figura 9.17: Trayectorias sobre el entorno de la semilla 2. Izquierda: episodio 0 con política aleatoria. Derecha: roll-out determinístico de la política aprendida, que alcanza la meta en 19 pasos.




Figura 9.18: Tasa de éxito de la navegación (media móvil de 50 episodios) para las tres semillas. La línea discontinua marca el nivel aleatorio (4.2 %) y la mejor semilla converge a 99 %.




Figura 9.19: Arquitectura del agente de navegación. El mismo crossbar R-STDP de las etapas anteriores, con $N = 16$ filas y $M = 4$ columnas, procesa el parche sensorial 3×3 y la posición para producir la acción.

9.4. Resultados y discusión

9.4.1. Métricas comparativas entre tareas

La Tabla 9.1 consolida los resultados de las tres tareas —control (CartPole-v1), clasificación visual (Visión 8×8) y navegación (Gridworld 10×10)— resueltas con el mismo agente R-STDP. En los tres casos el crossbar memristivo es el único sustrato de pesos: solo cambian las dimensiones del arreglo (24×12 , 64×8 y 16×4) y el codificador sensorial.

Tarea	Episodios	Semillas	Métrica final	$\bar{X}$	σ_X
CartPole-v1	2000	5	$\bar{R}_{200} = 77,8$, $\bar{R}_{\text{máx}} = 499$	0.57	0.30
Visión 8×8	5000	3	acierto(500) = 100 %	0.10	0.03
Navegación	800	3	éxito(200) = 50–82 %	0.34–0.38	0.27–0.34

Tabla 9.1: Comparación de las tres tareas resueltas con el mismo sustrato memristivo y la misma regla R-STDP. La métrica se evalúa sobre los últimos 200 episodios de cada corrida (500 en el caso de visión); $\bar{X}$ y σ_X son la media y la desviación estándar de la matriz de pesos al final del entrenamiento.

9.4.2. Especialización del sustrato según la tarea

La desviación estándar de la matriz de pesos resume cómo se reorganiza el crossbar: en visión X permanece casi plana ($\sigma_X \approx 0,02\text{--}0,03$, media $\approx 0,10$); en CartPole crece hasta $\sigma_X = 0,30$ con media 0.57; y en navegación alcanza $\sigma_X = 0,27\text{--}0,34$ con media 0.34–0.38. El contraste entre visión y navegación es el argumento central de este capítulo: el mismo arreglo físico se reconfigura de forma distinta según la tarea, y la especialización estructural (presente en navegación) no es una condición para el desempeño funcional (vista en visión), donde el decodificador discierne la clase a partir de diferencias mínimas de conductancia.

9.4.3. Ablaciones A/B/C/D

Se reprodujo el estudio de ablaciones del capítulo anterior (Figura 6.6) con el protocolo actual (`run_ablations_real_physics.py`, 300 episodios, física real $R_{\text{off}} = 16 \text{ k}\Omega$) sobre la arquitectura 24×12 . La Tabla 9.2 compara ambos protocolos.

Tabla 9.2: Estudio de ablaciones: protocolo original vs reproducción con física real. Los valores corresponden a $\bar{R}_{50}$ (media de recompensa en los últimos 50 episodios).

Config	Original	Reproducción	Δ
A (control base)	491,9 (3/5)	476,5 (5/5)	−3,1 %
B (sin adaptación térmica)	−39,0	+468,8 ¹	protocolo distinto ¹
C (sin elegibilidad)	−33,3	−35,9	+3,7 %
D (Hebbiano sin modulación)	−39,0	−39,0	±0,3 %

¹ La configuración B cambió de definición entre protocolos. En el original se implementó como temperatura fija baja ($T_{\text{init}} = 0,10$, `temp_decay` = 1,0) y colapsaba por congelamiento estocástico. En el protocolo actual se define como temperatura mínima reducida ($T_{\text{init}} = 1,0 \rightarrow T_{\text{mín}} = 0,10$, `temp_decay` = 0,995), y el agente converge normalmente. Ambos resultados son informativos: el primero confirma que la exploración inicial es indispensable; el segundo muestra que el agente es robusto a una reducción de la temperatura mínima.

Interpretación. Tres observaciones emergen de la comparación. Primero, las ablaciones C y D son *atractores robustos*: se reproducen con una variación menor al 4 % pese al no-determinismo medido entre corridas (C/0, misma semilla y script: −33,31 vs −34,56, $\Delta \approx 4 \%$). Esto confirma con evidencia nueva que la traza de elegibilidad y la modulación por recompensa son estrictamente indispensables para R-STDP, tal como se argumentó en el capítulo anterior. Segundo, el control base A pasa de 3/5 a 5/5 semillas convergentes con la física real, reduciendo la varianza entre semillas reportada en el protocolo original. Tercero, la nueva definición de B (temperatura mínima reducida, no congelada) no produce colapso, indicando que el agente es

robusto a la reducción del piso de exploración cuando el decaimiento térmico se preserva. En conjunto, las ablaciones reproducidas refuerzan los hallazgos del capítulo anterior y extienden la caracterización del sustrato bajo física realista.

9.4.4. Limitaciones

El aprendizaje episódico R-STDP sin buffer de experiencia exhibe varianza entre semillas: en CartPole el protocolo original observó 3 de 5 semillas convergentes y la corrida fresca 5 de 5, mientras que la navegación mantiene tasas de éxito final de 49.5 %, 70.5 % y 82 % en las tres semillas, atribuible a la aleatoriedad de la proyección inicial del codificador. El entorno Pendulum-v1 se excluyó del estudio como decisión metodológica: su recompensa densa presenta una varianza intrínseca que excede la señal del gradiente de política episódico (relación señal/ruido $\approx 0,7$), por lo que REINFORCE no puede asignar crédito de forma estable. Finalmente, la baja especialización de X en visión constituye una evidencia funcional sólida (100 % de acierto) pero estructuralmente débil, ya que el decodificador aprovecha diferencias mínimas de conductancia.

9.5. Análisis de costos

Apéndice A

Estructura del Código Fuente y Módulos

En este apéndice se detalla la organización modular del código fuente del proyecto **neurolab**, la jerarquía de paquetes en Python 3.14+ y la cobertura de la suite de pruebas unitarias.

A.1. Árbol de directorios del paquete **neurolab**

La estructura del código principal dentro de `neuromorphic_lab/neurolab/` se organiza de la siguiente manera:

```
neurolab/
|-- __init__.py
|-- core/
|   |-- __init__.py
|   |-- base_device.py          # Clase base abstracta MemristorBase
|   +-- constants.py           # Constantes físicas universalmente usadas
|-- devices/
|   |-- __init__.py
|   |-- strukov.py              # Modelo lineal Strukov 2008
|   |-- yakopcic.py             # Modelo asimétrico Yakopcic 2011
|   +-- volatile.py             # Modelo volátil HfO2 con relajación
|-- neurons/
|   |-- __init__.py
|   |-- lif.py                  # Neurona Leaky Integrate-and-Fire
|   +-- base_neuron.py          # Interfaz base de neuronas
|-- synapses/
|   |-- __init__.py
|   |-- memristive_synapse.py   # Conexión sináptica basada en memristor
|   +-- plasticity.py           # Módulo de reglas STDP y R-STDP
|-- circuits/
|   |-- __init__.py
```

```

|   +-- hybrid_circuit.py      # Circuito híbrido Memristor-LIF
|-- crossbar/
|   |-- __init__.py
|   |-- core.py                # Clase Crossbar unificada (M x N)
|   |-- drivers.py             # Decodificadores y drivers de línea
|   +-- selector.py            # Esquema de selección V/2
|-- gui/
|   |-- __init__.py
|   |-- main_window.py         # Ventana principal PySide6
|   |-- base_view.py           # Canvas base genérico BaseCrossbarCanvas
|   |-- crossbar_view.py       # Panel multitab Crossbar
|   |-- crossbar_2x2_view.py   # Vista interactiva 2x2
|   |-- crossbar_4x4_view.py   # Vista interactiva 4x4
|   +-- widgets/               # Componentes Matplotlib y sliders
|-- io/
|   |-- __init__.py
|   |-- config_loader.py       # Carga/guardado de YAML/JSON
|   +-- exporter.py            # Exportador de CSV y figuras
+-- validation/
    |-- __init__.py
    +-- metrics.py              # Cálculo de MAE, RMSE, RelErr y  $R^2$ 

```

A.2. Descripción de los módulos principales

Tabla A.1: Resumen de módulos del paquete **neurolab**.

Módulo	Responsabilidad Principal
neurolab.core	Define clases base abstractas, interfaces y constantes físicas universalmente usadas.
neurolab.devices	Implementa los modelos memristivos (Strukov, Yakopcic, Memristor Volátil).
neurolab.neurons	Implementa la neurona Leaky Integrate-and-Fire (LIF) y modelos adaptativos.
neurolab.synapses	Implementa la sinapsis memristiva y algoritmos de plasticidad (LTP/LTD, STDP, R-STDP).
neurolab.circuits	Ensambla el circuito híbrido sensor-neurona acoplando la corriente inyectada.
neurolab.crossbar	Gestiona matrices memristivas de dimensión $M \times N$, multiplicación VMM y esquema V/2.
neurolab.gui	Proporciona la interfaz gráfica PySide6 con renderizado dinámico interactivo.
neurolab.io	Gestiona el almacenamiento de datos, exportación en CSV y configuraciones YAML.
neurolab.validation	Contiene las funciones matemáticas para el cálculo de métricas (R^2 , MAE, RMSE).

A.3. Resumen de la suite de pruebas unitarias (Pytest)

La calidad del código y la estabilidad de las refactorizaciones se verifican mediante una suite de 87 pruebas automatizadas organizadas por módulo:

Tabla A.2: Distribución de las 87 pruebas unitarias e integradas (todas pasando satisfactoriamente).

Directorio de Pruebas	Número de Pruebas	Estado
tests/core/	12	PASS
tests/devices/	18	PASS
tests/neurons/	10	PASS
tests/synapses/	14	PASS
tests/crossbar/	16	PASS
tests/gui/	8	PASS
tests/validation/	9	PASS
Total	87	100 % Exitoso

A.4. Fragmentos de Código Centrales

A continuación se exponen fragmentos representativos del núcleo matemático del simulador *neurolab*, ilustrando la aplicación de tipado estático, modularidad y las leyes físicas descritas en el marco teórico.

A.4.1. Modelo Matemático de Strukov (*strukov.py*)

Implementación de la ecuación diferencial gobernante (dx/dt) encapsulada como un módulo matemático independiente.

```
class StrukovMathModel(BaseMathModel):
    """
    Modelo Matemático Determinista de Strukov et al. (Nature 2008).
    Ecuación diferencial de deriva iónica normalizada:
         $dx/dt = (\mu_v * R_{on} / D^2) * I(t)$ 
    """
    def compute_dxdt(
        self, state: float, voltage: float, current: float,
        electrical: ElectricalConfig, model_config: Optional[StrukovConfig] = None
    ) -> float:
        cfg = model_config if model_config is not None else StrukovConfig()

        # Computación de la tasa de cambio de la variable de estado
        return float((cfg.mu_v * electrical.r_on / (cfg.D ** 2)) * current)
```

A.4.2. Motor de Integración Base (`base_device.py`)

El núcleo de integración numérica de Euler donde convergen el modelo matemático, las funciones ventana y la inyección de procesos estocásticos.

```
def step(self, dt: float, voltage: float) -> None:
    # 1. Resolver corriente (Ley de Ohm analógica con resistencia actual)
    current = voltage / self.R

    # 2. Computar derivada pura (dx/dt) desde el modelo matemático subyacente
    dx_dt = self.math_model.compute_dxdt(self.x, voltage, current,
                                          self.electrical, self.model_config)

    # 3. Aplicar funciones ventana (ej. Biolek) y ruido termodinámico
    for modifier in self.modifiers:
        dx_dt = modifier.apply(self.x, voltage, current, dx_dt, dt, self)

    # 4. Integración explícita hacia adelante
    self.x += dx_dt * dt

    # 5. Saturación geométrica estricta a límites físicos
    if self.clip_x:
        self.x = max(0.0, min(1.0, self.x))

    self._history_x.append(self.x)
    self._history_r.append(self.R)
```

Apéndice B

Conjuntos de Datos, Scripts y Métricas de Validación

En este apéndice se proporciona la referencia exhaustiva de los conjuntos de datos de entrada, los scripts de validación numerados, las figuras de alta resolución generadas y la tabla maestra con las 27 métricas cuantitativas del proyecto.

B.1. Conjuntos de datos de referencia (CSVs)

Tabla B.1: Conjuntos de datos experimentales digitalizados incluidos en `neuromorphic_lab/validaciones/datos/`.

Archivo CSV	Artículo de Referencia	Descripción
<code>CvsT.csv</code>	Strukov et al. (2008) [1]	Corriente vs. Tiempo $I(t)$
<code>VvsT.csv</code>	Strukov et al. (2008) [1]	Voltaje de entrada $V(t)$
<code>WDvsT.csv</code>	Strukov et al. (2008) [1]	Ancho de capa $w(t)/D$
<code>VvsC_Prezioso.csv</code>	Prezioso et al. (2014) [2]	Ciclo I-V asimétrico en Al_2O_3
<code>Prezioso2015_S3a.csv</code>	Prezioso et al. (2015) [3]	Estado virgen Fig. S3a
<code>Prezioso2015_S3b.csv</code>	Prezioso et al. (2015) [3]	Formación de filamento S3b
<code>Prezioso2015_S3c.csv</code>	Prezioso et al. (2015) [3]	Conmutación reversibilidad S3c
<code>Wang2025_Sensor.csv</code>	Wang et al. (2025) [5]	Adaptación de frecuencia sensor HfO_2
<code>Jo2010_STDP.csv</code>	Jo et al. (2010) [8]	Curva de plasticidad STDP $\Delta G(\Delta t)$
<code>Jo2010_LTP_LTD.csv</code>	Jo et al. (2010) [8]	Modulación por pulsos LTP/LTD

B.2. Catálogo de figuras generadas

Tabla B.2: Catálogo consolidado de las 23 figuras representativas e integradas en la tesis.

#	Archivo de Figura	Script Generador	Descripción
1	fig_01_strukov.png	01_strukov_2008.py	Validación 6 paneles Strukov 2008
2	fig_02_prezioso.png	02_prezioso_2014.py	Ajuste de modelo Yakopcic Prezioso 2014
3	fig_03_lif.png	03_lif_analitica.py	Respuesta subumbral analítica LIF
4	fig_04_convergencia.png	04_convergencia.py	Análisis de orden de convergencia $p = 0,98$
5	fig_05_d2d_c2c.png	05_d2d_c2c.py	Variabilidad D2D y proceso C2C
6	fig_06_hfo2_isi.png	06_hfo2_isi.py	Sensor HfO ₂ + LIF en 2 ciclos
7	fig_07_r_x.png	07_r_x_consistencia.py	Consistencia analítica $R(x)$
8	fig_08_rs_x.png	08_rs_de_x.py	Verificación R_S proveniente de $x(t)$
9	fig_09_dt_extremos.png	09_dt_extremos.py	Fronteras de estabilidad con dt
10	fig_10_triangular.png	10_triangular.py	Respuesta a señal triangular
11	fig_11_ruido.png	11_ruido.py	Sensibilidad a ruido estocástico
12	fig_12_estadistica.png	12_estadistica.py	Tests estadísticos acumulados
13	fig_13_wang.png	13_wang_2025.py	Comparativa cuantitativa Wang 2025
14	fig_14_ltp_ltd.png	14_ltp_ltd.py	Trenes de pulsos LTP/LTD
15	fig_15_stdp.png	15_stdp.py	Ventana de aprendizaje STDP
16	fig_16_ciclo.png	16_ltp_ltd_ciclo.py	Reversibilidad tras 100 ciclos
17	fig_17_stdp_spikes.png	17_stdp_spikes.py	Formas de onda de pulsos STDP
18	fig_18_stdp_temporal.png	18_stdp_temporal.py	Acumulación temporal de pesos
19	fig_19_iv_hysteresis.png	19_iv_histeresis.py	Lazo de histéresis sináptico
20	fig_20_vi_ltp_ltd.png	20_vi_ltp_ltd.py	Caracterización V-I-R-G
21a-d	fig_21a-d_crossbar_*.png	21_crossbar_1x1.py	Operación matricial 1×1
22	fig_22_prezioso_v2.png	22_prezioso_v2.py	Validación Prezioso V2 extendida
23	fig_23_s3a.png	prezioso2015_s3.py	Estado virgen Prezioso 2015 S3a

B.3. Tabla maestra de las 27 validaciones cuantitativas

Tabla B.3: Resumen consolidado de las 27 validaciones del proyecto Neuromorphic Lab.

ID	Referencia / Origen	Script	Métrica Principal	Valor Obtenido
V01	Strukov 2008	01_strukov_2008.py	R^2 en corriente $I(t)$	$> 0,99$
V02	Strukov 2008	07_r_x_consistencia.py	Error relativo $R(x)$	0,00 %
V03	Strukov 2008	04_convergencia.py	Orden de convergencia p	0,98
V04	Strukov 2008	09_dt_extremos.py	Umbral máximo de dt	10^{-3} s
V05	Strukov 2008	10_triangular.py	Rango del estado $x(t)$	[0,0, 0,38]
V06	Prezioso 2014	02_prezioso_2014.py	R^2 ciclo completo	0,9640

Continúa en la siguiente página...

Tabla B.3: Resumen consolidado de las 27 validaciones (Continuación)

ID	Referencia / Origen	Script	Métrica Principal	Valor Obtenido
V07	Prezioso 2014	22_prezioso_v2.py	Asimetría SET/RESET	Ratio $I_{RESET}/I_{SET} = 3,0$
V08	Prezioso 2015	prezioso2015_s3.py	Estado virgen S3a	Cualitativo OK
V09	Prezioso 2015	prezioso2015_s3.py	Electro-formación S3b	Cualitativo OK
V10	Prezioso 2015	prezioso2015_s3.py	Conmutación S3c	Cualitativo OK
V11	Wang 2025	06_hfo2_isi.py	Diferencia ISI entre ciclos	$< 0,3\%$
V12	Wang 2025	08_rs_de_x.py	Error R_S vs $x(t)$	$0,00\%$
V13	Wang 2025	13_wang_2025.py	Factor de compresión	$27,2\times$
V14	Jo 2010	15_stdp.py	Ventana STDP (R^2)	$> 0,98$
V15	Jo 2010	17_stdp_spikes.py	Solapamiento de pulsos	$\Delta V_{pico} = 450 \text{ mV}$
V16	Jo 2010	18_stdp_temporal.py	Acumulación temporal	$R^2 = 0,99$
V17	Jo 2010	14_ltp_ltd.py	Potenciación $\Delta G > 0$	Verificado
V18	Jo 2010	14_ltp_ltd.py	Depresión $\Delta G < 0$	Verificado
V19	Jo 2010	16_ltp_ltd_ciclo.py	Error de retorno (100 c.)	$< 1,0\%$
V20	Jo 2010	20_vi_ltp_ltd.py	Coherencia V-I-R-G	Error = $0,00\%$
V21	Jo 2010	19_iv_histeresis.py	Lazo pinzado en origen	$I(0) = 0,0 \text{ nA}$
V22	Solución Exacta	03_lif_analitica.py	R^2 respuesta subumbral	1,0000
V23	Variabilidad	05_d2d_c2c.py	Test KS p -valor D2D	$0,8959$
V24	Variabilidad	05_d2d_c2c.py	Error varianza C2C	$3,62\%$
V25	Ruido	11_ruido.py	Coefficiente variación I_{pp}	115%
V26	Estadística	12_estadistica.py	Test normalidad KS	$p > 0,05$
V27	Crossbar 1x1	21_crossbar_1x1.py	Operación VMM ($I = G \cdot V$)	Error = $0,00\%$

Bibliografía

- [1] D. B. Strukov, G. S. Snider, D. R. Stewart, and R. S. Williams, “The missing memristor found,” *Nature*, vol. 453, no. 7191, pp. 80–83, 2008.
- [2] M. Prezioso, F. Merrikh-Bayat, B. D. Hoskins, G. C. Adam, K. K. Likharev, and D. B. Strukov, “Training and operation of an integrated neuromorphic network based on metal-oxide memristors,” *Nature Communications*, vol. 5, p. 4801, 2014.
- [3] M. Prezioso, F. Merrikh-Bayat, B. D. Hoskins, G. C. Adam, K. K. Likharev, and D. B. Strukov, “Demonstration of a 100-synapse metal-oxide memristive crossbar array,” *Nature*, vol. 521, pp. 61–64, 2015.
- [4] C. Yakopcic, T. M. Taha, G. Subramanyam, R. E. Pino, and S. Rogers, “A memristor device model,” *IEEE Electron Device Letters*, vol. 32, no. 10, pp. 1436–1438, 2011.
- [5] X. Wang, Y. Zhu, Z. Zhou, X. Chen, and X. Jia, “Memristor-based spiking neuromorphic systems toward brain-inspired perception and computing,” *Nanomaterials*, vol. 15, no. 14, p. 1130, 2025.
- [6] R. Yang, K. Terabe, G. Yao, T. Tsuruoka, T. Hasegawa, J. K. Gimzewski, and M. Aono, “Synaptic plasticity and dynamic reasoning in a volatile oxide memristor,” *Nature Communications*, vol. 8, p. 15199, 2017.
- [7] G.-q. Bi and M.-m. Poo, “Synaptic modifications in cultured hippocampal neurons: dependence on spike timing, synaptic strength, and post-synaptic cell type,” *Journal of Neuroscience*, vol. 18, no. 24, pp. 10464–10472, 1998.
- [8] S. H. Jo, T. Chang, I. Ebong, B. Bhadviya, P. Mazumder, and W. Lu, “Nanoscale memristor device as synapse in neuromorphic systems,” *Nano Letters*, vol. 10, no. 4, pp. 1297–1301, 2010.